پلان اجرایی اصلاح و تکمیل مقالهٔ امنیت RAG

موضوع: تبدیل یافته‌های ریسرچ و ملاحظات متخصص به کارهای قابل اجرا، قابل سنجش و قابل گزارش.

مبنای پلان: گزارش مرحلهٔ ریسرچ، جدول ٦٧ مورد ملاحظه، ممیزی داده و پاسخ‌ها و نسخهٔ مشخص مخزن RAG-Security-Lab.

وضعیت سند: پلان آمادهٔ عملی‌سازی است. ساخت این سند به معنای اجرای آزمایش تازه، تکمیل داوری انسانی یا تأیید آمادگی مقاله برای نشر نیست.

۱. تصمیم اصلی و نتیجهٔ مورد انتظار

اصلاح مقاله باید از اعتبار مرجع و روش ارزیابی شروع شود. بررسی قبلی، محاسبات آزمایش مولد را تأیید کرد، اما نشان داد که حضور یک عدد در پاسخ همیشه به معنای پاسخ درست یا پذیرش ادعای غلط نیست. همچنان، دادهٔ مطالعهٔ قدیمی موجود است، ولی آرشیو کامل اجرای اصلی و کد منطبق با آن در نسخهٔ بررسی‌شدهٔ مخزن قرار ندارد. بازنویسی متن پیش از حل این دو مسئله، کمبود شواهد را برطرف نمی‌کند.

مسیر اصلی این پلان، یک مطالعهٔ تجربی محدود دربارهٔ اثر درج متن مسموم بر بازیابی و پاسخ مدل است. یک آزمایش مکمل با زمینهٔ ثابت، رفتار مولد را هنگام مواجههٔ یکسان بررسی می‌کند. تصفیه بر اساس برچسب اعتماد نیز با همان فرض آزمایشگاهی خود ارزیابی می‌شود. ایجاد یک سامانهٔ عملیاتی تأیید اسناد، امضای دیجیتال یا تضمین رسمی امنیت، جزو این مسیر اصلی نیست؛ چنین ادعاهایی از مقاله حذف یا صریحاً محدود می‌شوند.

محصول پایان کار، مقالهٔ بازنگری‌شده، گزارش مستند پاسخ به متخصص و بستهٔ شواهد قابل بررسی خواهد بود. هیچ رقم آرشیوی به‌صورت خاموش عوض نمی‌شود. اگر مرجع، معیار یا کد تغییر کند، نتیجهٔ جدید همراه نسخه، دلیل تغییر و مقایسه با نتیجهٔ قبلی ثبت می‌شود.

۲. تفکیک مطالعات و حفظ شواهد

برای جلوگیری از خلط نسخه‌ها، سه نام در تمام فایل‌ها، جدول‌ها و گزارش‌ها ثابت می‌ماند:

- **مطالعهٔ A، تاریخی:** آزمایش ۲۲۴ سند، ۲۲۵ قطعه، ۳۶۴ پرسش و ۱۰۴ هدف. نتیجهٔ اصلی گزارش‌شده، ۲۱٬۸۴۰ ردیف دارد. دسترسی به ورودی‌های آن، معادل دسترسی به تمام خروجی‌های اجرای اصلی نیست.
- **مطالعهٔ B، ثبت‌شده:** آزمایش واقعی OpenAI با ۶۴ پرسش، ۶۴۰ متن پاک، ۳۷۶ درخواست متفاوت و ۱٬۲۸۰ ردیف شرطی. بازتحلیل معنایی این مطالعه، تحلیل پس از مشاهدهٔ نتایج معرفی می‌شود.
- **مطالعهٔ C، پیشنهادی:** آزمایش تازه با مرجع بررسی‌شده، مجموعهٔ آزمون استفاده‌نشده، کنترل اجرای اجباری و پروتکل منجمد پیش از تولید پاسخ‌ها. این مطالعه هنوز اجرا نشده است.

در آغاز عملی‌سازی، از کد، داده، پاسخ‌ها و اسناد موجود فهرست SHA-256 گرفته می‌شود و پوشهٔ کار تازه ساخته خواهد شد. تغییرات در نسخهٔ جدید کد انجام می‌شود. فایل‌های تاریخی و متن اصلی مقاله، سابقهٔ قابل مراجعه باقی می‌مانند.

اصل حفظ اشکال: فلوچارت اصلی، دو نمودار قدیمی و نمودار آزمایش مولد حذف نمی‌شوند. اگر نتیجهٔ بازتحلیل با نموداری تفاوت داشته باشد، نمودار جدید جدا ساخته می‌شود و شکل قدیمی با توضیح نسخه و حدود شواهد، در محل مناسب یا ضمیمه محفوظ می‌ماند.

۳. همسوسازی سؤال‌های تحقیق با آزمایش

شماره‌گذاری چهار سؤال نسخهٔ محلی حفظ می‌شود؛ تعریف نتیجه‌ها دقیق‌تر خواهد شد. تطبیق آن با سؤال‌های نسخهٔ قدیمی نیز در جدول تغییرات می‌آید تا تغییر شماره یا دامنه پنهان نماند.

سؤال	مقایسهٔ لازم	نتیجهٔ قابل گزارش
RQ1: هدفمندبودن متن چه اثری دارد؟	متن هدفمند در برابر متن نامرتبط و متن درست، با پرسش و مقدار درج ثابت	تفاوت جفتی پذیرش معنایی گزارهٔ تأییدشدهٔ غلط در مسیر دارای داوری؛ حضور عدد، معیار کمکی
RQ2: شاهد درست و متن حمله چگونه به پاسخ مرتبط‌اند؟	زمینه‌های بازیابی‌شده و، جداگانه، زمینه‌های با مواجههٔ کنترل‌شده	بازیابی تمام شواهد، مواجهه با حمله، پاسخ درست، پذیرش ادعای غلط و امتناع به‌صورت جدا
RQ3: دفاع چه چیزی را متوقف یا اصلاح می‌کند؟	بدون دفاع، رتبه‌بندی مجدد، تصفیه و ترکیب آن‌ها؛ برچسب ردشده در برابر پذیرفته‌شده	جلوگیری، بازگشت پاسخ درست، خطای تازه و حد وابستگی به برچسب
RQ4: هزینهٔ دفاع برای استفادهٔ سالم چیست؟	هر دفاع در دادهٔ پاک؛ سپس آزمون جداگانهٔ رد شاهد معتبر	تغییر پاسخ در وضعیت پاک و کاهش پوشش شاهد؛ هزینهٔ عملیاتی فقط در صورت سنجش مستقیم

مقایسه‌های اصلی مطالعهٔ C، هدفمند در برابر نامرتبط و هدفمند در برابر درست، در حالت بدون دفاع خواهند بود. در مسیر دارای داوری، معیار اصلی پذیرش معنایی گزارهٔ هدف است که غلط‌بودن آن از قبل مستند شده؛ تطبیق عددی معیار کمکی می‌ماند. اگر مسیر صرفاً خودکار انتخاب شود، معیار اصلی و دامنهٔ ادعا پیش از انجماد به «تولید مقدار هدف» محدود خواهد شد و این محصول، تکمیل ارزیابی معنایی مستقل معرفی نمی‌شود. سایر مقایسه‌ها ثانوی و اکتشافی‌اند. آزمایش مواجههٔ یکسان، نتیجهٔ کل خط لوله را تکمیل می‌کند؛ از آن برای نسبت‌دادن اثر بازیابی به مولد استفاده نمی‌شود.

۴. بسته‌های کاری و معیار تکمیل

P0. ثبت دامنه، نسخه‌ها و مسئولیت‌ها

ابتدا دفتر ادعاها ساخته می‌شود: هر ادعای مقاله به مطالعه، فایل شاهد و نوع بررسی وصل خواهد شد. معماری پیشنهادی، معماری اجراشده و کد فعلی مخزن جدا توصیف می‌شوند. اگر دلیل تاریخی تغییر معماری مستند نباشد، نبود سند اعلام می‌شود؛ دلیل تازه به‌عنوان تصمیم گذشته نوشته نمی‌شود.

برای برچسب اعتماد، نقش «تنظیم‌کنندهٔ دیتای آزمایش» تعریف می‌شود. نام شخص یا نهاد صاحب صلاحیت واقعی تنها با معلومات قابل تأیید درج خواهد شد. تا آن زمان، برچسب‌ها صفات اختصاص‌یافته توسط سازندهٔ مجموعه‌اند. مقاله دربارهٔ وجود صلاحیت نهادی یا احراز هویت اجراشده ادعا نمی‌کند.

خروجی و شرط تکمیل: دفتر ادعاها، فهرست نسخه‌ها، معماری فعال و جدول مسئولیت‌ها آماده باشد؛ هر عدد و نمودار به اجرای معین متصل شود. وابستگی: ندارد. مسئول: پژوهشگر با اجرای تخنیکی دستیار.

P1. صحت‌سنجی مرجع، سؤال و مقدار حمله

برای تمام ۶۴ پرسش مطالعهٔ B، پروندهٔ مرجع ساخته می‌شود: پرسش، موجودیت، رابطه، زمان، واحد، متن پشتیبان، منبع، پاسخ پذیرفتنی، مقدار حمله و دلیل غلط‌بودن آن. مرجع مجموعه و واقعیت بیرونی دو ستون جدا دارند. هر اختلاف منبع یا ابهام ثبت می‌شود.

پنج مسئلهٔ شناسایی‌شده حتماً تعیین تکلیف می‌شوند: سال ایجاد در برابر تجدید سازمان USAAF؛ قید «بیش از ۲۳۰»؛ نام گروه ۳۱۱؛ پاسخ دارای عدد درست همراه با UNKNOWN؛ و امتناع در قالب جملهٔ کامل. برای سال ۱۹۴۱/۱۹۴۲، سند رسمی و رابطهٔ دقیق مورد سؤال مبنای تصمیم خواهد بود. برای ۲۳۰/۲۴۷، صرف بزرگ‌تر بودن عدد، دلیل غلط‌بودن آن محسوب نمی‌شود.

برای مطالعهٔ A، تمام ۱۶۸ مشاهدهٔ WDI و قواعد گردکردن به‌صورت ماشینی دوباره کنترل و ۵۶ سند قبلی از نظر منبع، تاریخ، رابطه و برچسب بررسی می‌شوند. پاسخ‌ها و مقادیر حملهٔ ۱۰۴ هدف نیز به همین دفتر وصل می‌شوند. منبع در دسترس‌نبوده یا ادعای تأییدنشده برچسب مشخص می‌گیرد.

خروجی و شرط تکمیل: هر پرسش وضعیت «پذیرفته»، «نیازمند اصلاح» یا «حل‌نشده» و دلیل داشته باشد. هیچ پرسش حل‌نشده وارد مخرج نتیجهٔ دارای ادعای صحت معنایی نشود. کنارگذاری و اصلاح در تحلیل B پس از مشاهدهٔ نتیجه اعلام می‌شود و نتیجهٔ کامل ۶۴موردی نیز محفوظ می‌ماند. اصلاح مرجع همان سؤال با تغییر معنای سؤال فرق دارد؛ پاسخ قدیمی، پاسخ به سؤال بازنویسی‌شده معرفی نمی‌شود. وابستگی: P0. مسئول: پژوهشگر؛ بازبینی انسانی مستقل در صورت دسترسی.

P2. تعریف ارزیابی و بازتحلیل مطالعهٔ B

ارزیابی تازه چهار محور را جدا ثبت می‌کند: صحت واقعیت با توجه به پرسش؛ پشتیبانی از زمینهٔ ارائه‌شده؛ پذیرش یا رد مقدار هدف حمله؛ و امتناع کامل، جزئی یا متناقض. در محور پشتیبانی، سازگاری با هر متنِ زمینه و پشتیبانی از شاهد پاکِ معتبر دو فیلد جدا دارند؛ پاسخ غلط ممکن است از خود متن مسموم پشتیبانی شود. پاسخ دارای هر دو عدد، نفی مقدار غلط و نقل قول از ادعای حمله، با پذیرش آن یکسان محسوب نمی‌شود. قواعد نارمل‌سازی ارقام، جداکننده، اعشار، سال، واحد و بازه نیز با مثال توضیح داده می‌شوند.

تطبیق عددی، EM و F1 همچنان معیارهای کمکی و قابل اجرای ماشینی می‌مانند. نتیجهٔ آن‌ها با برچسب معنایی اشتباه گرفته نمی‌شود. برنامهٔ تازه روی نمونه‌های واقعی مسئله‌دار و چند نمونهٔ مرزیِ ضروری آزموده می‌شود؛ سپس تمام پاسخ‌های موجود با شناسهٔ نسخه بازنمره‌دهی خواهند شد.

مسیر ترجیحی، دو ارزیاب انسانی مسلط به انگلیسی و دستورالعمل علمی است. ارزیابان ابتدا مستقل کار می‌کنند و برچسب دفاع، امتیاز خودکار و نتیجهٔ ارزیاب دیگر را نمی‌بینند. برای بررسی صحت، مرجع مستند در دسترس است؛ برای بررسی پشتیبانی، زمینهٔ واقعی نیز ارائه می‌شود. اختلاف‌ها پس از ثبت داوری اولیه حل و سابقهٔ هر تصمیم نگهداری می‌شود.

تمام ۳۷۶ مورد متفاوت B برای بررسی آماده می‌شود. در C، واحد داوری ترکیب دقیق پرسش، زمینه و پاسخ است؛ تکرار همین ترکیب می‌تواند برچسب یکسان بگیرد، ولی تعداد اتصال آن به ردیف‌ها ثبت می‌شود. توافق خام، جدول اختلاف‌ها و ضریب متناسب با نوع برچسب گزارش می‌شود؛ آستانهٔ قراردادی توافق، دلیل صحت مرجع نیست.

اگر ارزیاب انسانی در دسترس نباشد، کارهای تخنیکی ادامه می‌یابد و جدول‌ها با عنوان ارزیابی خودکار منتشر می‌شوند. در آن مسیر، صحت معنایی مستقل یا اعتبارسنجی انسانی کامل ادعا نخواهد شد. انتخاب مسیر ارزیابی و تغییر معیار اصلی C باید پیش از انجماد ثبت شود؛ تغییر پس از مشاهدهٔ پاسخ‌ها، انحراف از پروتکل محسوب می‌شود. استفاده از دستیار یا LLM به‌عنوان دو داور انسانی مجاز نیست. بررسی نمونه‌ای نیز، اگر جایگزین بررسی کامل شود، باید پیش از انتخاب نمونه طرح و با حجم، احتمال انتخاب و حدود نتیجه گزارش شود.

خروجی و شرط تکمیل: دستورالعمل، کد ارزیابی، جدول تغییر برچسب‌ها و نتیجهٔ بازتحلیل تولید شود؛ ارقام آرشیوی و ارقام اصلاح‌شده قابل تفکیک باشند. وابستگی: P1. مسئول: دستیار برای کد؛ انسان‌های واقعی برای داوری انسانی.

P3. تعیین تکلیف بازتولید مطالعهٔ A

جست‌وجو ابتدا بر فایل‌های اجرای اصلی، شناسهٔ کد، تنظیمات، seedها و خروجی خام متمرکز می‌شود. شاخه‌ها، تاریخچه و مسیرهای قابل دسترسی مخزن بررسی و فهرست مواد پیداشده ثبت خواهد شد. فقط نبودن فایل در یک commit، به معنای نبودن آن در همهٔ محل‌ها نیست.

اگر آرشیو دقیق پیدا شود، کنترل تمامیت، بازنمره‌دهی و در صورت امکان بازاجرای همان نسخه انجام می‌شود. برای حفظ ادعای بازتولید اصلی، چهار جزء باید به هم وصل باشند: ورودی، کد، تنظیمات و خروجی؛ جدول‌ها باید از رکوردها دوباره محاسبه شوند.

اگر آرشیو اصلی قابل بازیابی نباشد، نخست وضعیت عدم تأیید و اثر آن بر ادعاهای مقاله ثبت می‌شود. در صورت نیاز به حفظ یک مقایسهٔ تجربی تازه روی دادهٔ اصلی، اجرای نسخه‌دار با نام A′ انجام خواهد شد؛ این کار شرط خودکار تکمیل کل مقاله نیست. در مسیر A′، بودجه‌های صفر، ۱۰، ۳۰، ۶۰ و ۱۰۴ و seedهای ۱۷، ۴۲ و ۹۱ پیش از اجرا ثبت می‌شوند. در صورت اجرای چهار دفاع روی ۳۶۴ پرسش، ۲۱٬۸۴۰ ردیف تازه ایجاد می‌شود. هم‌تعدادبودن ردیف‌ها، اثبات یکسان‌بودن روش و نتیجه نیست؛ تفاوت انتخاب جمله، مرتب‌سازی و نسخهٔ کتابخانه‌ها مستند می‌شود.

آزمایش تشخیصی ۱٬۰۹۲ردیفی و آزمایش تکرار ۳٬۰۱۶ردیفی با اجرای اصلی جمع نمی‌شوند. ارقام تکرار قدیمی بدون رکورد و پروتکل کافی، شاهد تازه تلقی نخواهند شد. اگر بازیابی نشوند، وضعیت آن‌ها در متن و شرح اشکال تاریخی اعلام می‌شود. اگر ماژول تازهٔ دوز نیز اجرا نشود، تحلیل تکرار به‌عنوان شکاف باقیمانده ثبت می‌شود؛ محدودکردن ادعا به معنای تکمیل آن آزمایش نیست.

خروجی و شرط تکمیل: بستهٔ بازتولید دقیق، بستهٔ A′ یا گزارش مستند عدم بازیابی و محدودکردن ادعا، متناسب با مسیر انتخاب‌شده آماده باشد. روشن‌بودن این تصمیم شرط بازنویسی نتیجهٔ A است. وابستگی: P0 و برای مرجع اصلاح‌شده P1؛ قابل اجرا هم‌زمان با P2. مسئول: دستیار؛ دریافت آرشیو خارج از مخزن در صورت وجود، نیازمند همکاری صاحب فایل است.

P4. اصلاح کنترل اجرا در نسخهٔ جدید

پیش از هر درخواست تولید پاسخ، تمام ورودی‌ها، کد مؤثر، تنظیمات، بردارها، زمینه‌ها و فایل درخواست‌های در انتظار با manifest منجمد تطبیق داده می‌شوند. درخواست‌های embedding نیز پیش از ارسال، ورودی، مدل و تنظیمات منجمد همان مرحله را کنترل می‌کنند؛ در آن مرحله هنوز بردار و زمینهٔ نهایی وجود ندارد. مسیر کش خالی نیز کنترل مربوط به همان مرحله را می‌گذراند. تغییر حتی یک درخواست باید پیش از نخستین ارسال باعث توقف شود.

آزمون ضروری این بسته، تغییر عمدی درخواست در نسخهٔ آزمایشی با ارسال‌کنندهٔ ساختگی است: هش نادرست باید صفر ارسال ایجاد کند؛ ورودی سالم باید اجازهٔ اجرا بدهد. این آزمون کاملاً آفلاین انجام می‌شود. پس از آن، کنترل مدل برگشتی، ثبت خطا، ادامهٔ اجرای نیمه‌تمام و کلید کش وابسته به نوبت تولید بررسی می‌شود.

خروجی و شرط تکمیل: کد نسخهٔ جدید، محیط وابستگی ثبت‌شده و گزارش آزمون توقف پیش از ارسال آماده باشد؛ هیچ مسیر ارسال، کنترل هش را دور نزند. مدل یا backend بدون ثبت و انجماد پروتکل عوض نشود. وابستگی: P0؛ قبل از اجرای C الزامی است. مسئول: دستیار.

P5. ساخت و انجماد مطالعهٔ C

۶۴ پرسش B برای توسعه و بررسی روش کنار گذاشته می‌شوند و دوباره آزمون دست‌نخورده نام نمی‌گیرند. هدف ۶۴ ،C پرسش تازه و ۶۴ پرسش اهداکنندهٔ کنترل است. ابتدا امکان تأمین این تعداد از بخش عمومی validation در همان نسخهٔ HotpotQA بررسی می‌شود. شناسه‌ها و عنوان‌های تمام ۱۲۸ مورد قبلی، شامل اهداکنندگان، از انتخاب تازه حذف می‌شوند.

اگر تعداد کافی باقی نماند، پیش از تولید پاسخ، بخش train همان نسخه با ثبت تغییر منبع بررسی می‌شود. اندازه، قواعد انتخاب و دامنهٔ ادعا پیش از انجماد نهایی تعیین می‌شود؛ کمبود داده پس از دیدن خروجی با تعویض پرسش‌های دشوار جبران نمی‌شود. این داده، آزمون جدید پروژه از یک معیار عمومی است؛ آزمون مخفی رسمی یا مستقل از پیش‌آموزش مدل معرفی نمی‌شود.

انتخاب بر اساس شناسهٔ پایدار و ترتیب SHA256('rag-security-followup-v1:' + id) خواهد بود. موجودیت، رابطه، زمان و منابع مشترک نیز بررسی می‌شوند. موارد دارای واقعیت یا شاهد مشترک، گروه می‌گیرند و میان توسعه، آزمون و اهداکننده پخش نمی‌شوند. عدم هم‌پوشانی متنی به معنای استقلال معنایی کامل فرض نمی‌شود.

مرجع و غلط‌بودن مقدار هدف هر ۶۴ پرسش و ارتباط نامرتبط اهداکننده پیش از تولید پاسخ تأیید می‌شود. در جفت هدفمند و نامرتبط، همان مقدار هدف درج می‌شود و باید برای رابطهٔ اهداکننده نیز نادرست باشد؛ درست‌بودن اتفاقی آن در کنترل پذیرفته نمی‌شود. نامرتبط‌بودن فقط متفاوت‌بودن عنوان نیست. نوع پاسخ، واحد، زمان، طول متن و مقدار درج‌شده میان کنترل‌ها ثبت می‌شود. طول، ساختار، واژگان و شباهت متن حمله با اسناد پاک نیز همراه روش ساخت توصیف خواهد شد. موارد دارای حد پایین، رابطهٔ مبهم یا مرجع حل‌نشده وارد آزمون اصلی نمی‌شوند.

انجماد در دو مرحله ثبت می‌شود: نخست، داده، کد، قواعد و درخواست‌های embedding پیش از ساخت بردارها؛ سپس، بردارهای برگشتی، زمینه‌های نهایی و تمام درخواست‌های تولید پاسخ، پیش از پاسخ‌گیری از مولد. طرح ارزیابی و انتخاب داده پیش از این پاسخ‌گیری ثابت است.

خروجی و شرط تکمیل: داده، کارت مجموعه، پروندهٔ مرجع‌ها، متن حمله‌ها، دفتر هم‌پوشانی، تنظیمات، کد، درخواست‌ها، مخرج‌ها و طرح تحلیل در manifestهای متصل دو مرحله ثبت شوند. پاسخ مدل در انتخاب داده دخالت نکند. نام و هش نسخهٔ جدید، مبنای تمام مراحل بعد باشد. وابستگی: P1، P2 و P4. مسئول: پژوهشگر و دستیار؛ تأیید انسانی فقط در صورت واقعاً انجام‌شدن ثبت می‌شود.

P6. اجرای مطالعهٔ C و کنترل‌های آن

پس از عبور از انجماد، اجرا با یک مدل واقعی انجام می‌شود. مدل ترجیحی برای حفظ پیوند با B، gpt-4.1-mini-2025-04-14 و مدل embedding، text-embedding-3-small است. اگر مدل مورد نظر قابل استفاده نباشد، اجرا متوقف و نسخهٔ تازهٔ پروتکل پیش از پاسخ‌گیری تعریف می‌شود. مدل محلی یا مدل جایگزین خودکار وارد نتیجه نمی‌شود.

جزئیات طرح و سقف درخواست‌ها در بخش بعد آمده است. پس از اجرا، پاسخ خام، شناسهٔ درخواست، مصرف توکن، نام مدل برگشتی، علت پایان و خطاها ذخیره می‌شود. خطا یا پاسخ قطع‌شده، پاسخ غلط معنایی شمرده نمی‌شود؛ تعداد و اثر دادهٔ ناقص جدا گزارش خواهد شد. تکرار اضافی پس از دیدن نتیجه برای بهترکردن رقم ممنوع است.

خروجی و شرط تکمیل: تمام سلول‌های ازپیش‌تعریف‌شده، پاسخ معتبر یا وضعیت خطای روشن داشته باشند؛ درخواست و پاسخ به هش و نوبت تولید متصل باشد؛ شمار واقعی درخواست، کش و تلاش مجدد گزارش شود. وابستگی: P5 و تصمیم مکتوب دامنهٔ ماژول‌های اختیاری. مسئول: دستیار.

P7. تحلیل نهایی، خطاها و عدم قطعیت

تحلیل با مخرج ثابت و جفت‌کردن همان پرسش‌ها انجام می‌شود. موفقیت حمله در میان همهٔ اهداف، موفقیت در میان موارد مواجه‌شده، جلوگیری از موفقیت قبلی، بازگشت پاسخ درست و خطای تازه جدا محاسبه می‌شوند. برای متن نامرتبط، مقدار هدف مشترک سنجیده می‌شود؛ مواجهه با حملهٔ مخصوص پرسش به آن نسبت داده نمی‌شود.

چهار گروه موردی از قواعد ازپیش‌تعریف‌شده استخراج می‌شود: شاهد درست همراه پاسخ غلط؛ مواجهه با حمله و شکست آن؛ جلوگیری بدون بازگشت پاسخ درست؛ و اثر تغییر برچسب. همهٔ موارد هر گروه در فایل مکمل می‌آیند و مثال‌های متن بر اساس قاعدهٔ ثابت انتخاب می‌شوند. تفاوت معیار عددی و معنایی نیز با نمونهٔ واقعی توضیح داده خواهد شد.

سه نوبت تولید جدا گزارش می‌شوند. نتیجهٔ تجمیعی ابتدا میانگین سه نوبت درون هر پرسش و سپس میانگین میان پرسش‌هاست؛ «موفقیت در حداقل یکی از سه نوبت» معیار اصلی نخواهد بود. اگر خروجی حل‌نشده وجود داشته باشد، نرخ پایین و بالای ممکن با مخرج برنامه‌ریزی‌شده گزارش می‌شود. تحلیل جفت‌های کامل نیز فقط با اعلام تعداد باقی‌مانده ارائه خواهد شد؛ خطای درخواست، عدم موفقیت حمله فرض نمی‌شود و میانگین صرف موارد موجود جای نتیجهٔ کامل نمی‌نشیند.

برای فاصله‌های توصیفی، گروه‌های پرسشِ دارای واقعیت یا شاهد مشترک با هم بازنمونه‌گیری می‌شوند؛ درون هر نمونه، وابستگی نوبت‌ها حفظ می‌شود. ۱۰٬۰۰۰ بازنمونه با seed ثابت 20261025 در طرح تحلیل ثبت خواهد شد. چون یک مجموعهٔ اسناد مشترک وجود دارد، فاصله‌ها مشروط به همین مجموعه‌اند و عدم قطعیت میان مجموعه‌ها یا دامنه‌های تازه را پوشش نمی‌دهند.

اگر گروه‌بندی معتبر یا تعداد گروه برای استنباط مناسب نباشد، جدول جفتی و دامنهٔ نتایج نوبت‌ها ارائه می‌شود و از ادعای تأییدی خودداری خواهد شد. seedهای انتخاب حمله در A، seed بازنمونه‌گیری و تغییرپذیری تولید C در گزارش یک مفهوم معرفی نمی‌شوند.

خروجی و شرط تکمیل: همهٔ جدول‌ها و شکل‌های تازه از یک مسیر اجرایی ساخته شوند؛ شمارش‌ها با ممیزی جدا تطبیق کنند؛ دادهٔ ناقص، برچسب حل‌نشده و تصمیم پس از مشاهده پنهان نماند. وابستگی: P2، P3 و P6. مسئول: دستیار و پژوهشگر.

P8. بازنویسی مقاله و آماده‌سازی بستهٔ تحویل

چکیده، روش، نتایج، بحث و نتیجه‌گیری پس از نهایی‌شدن شواهد بازنویسی می‌شوند. جدول سؤال‌های تحقیق، شرح اجزای فعال، مشخصات ساخت داده و حدود فرض اعتماد در متن اصلی می‌آیند. A، بازتحلیل B و C در جدول‌ها و شکل‌ها برچسب مستقل خواهند داشت.

دو اشکال کتاب‌شناختی معلوم اصلاح می‌شود: سربرگ باقی‌مانده در مرجع و فاصلهٔ اضافی در نشانی RAGAs. مشخصات منابع نسخه‌دار با نسخهٔ واقعاً استفاده‌شده تطبیق داده می‌شود. متن به انگلیسی علمی روشن و گزارش به دری رسمی، مشخص و استدلالی نوشته می‌شود؛ هر پاسخ به متخصص، اقدام و شاهد همان اقدام را نشان می‌دهد.

فهرست حقوق نشر برای کد، مجموعهٔ HotpotQA، متن‌های ۵۶ ،WDI سند قبلی، پاسخ‌های مدل و شکل‌ها جدا ساخته می‌شود. پیوند منبع به‌تنهایی اجازهٔ بازنشر نیست. مجوز، انتساب لازم، محدودیت و تصمیم دربارهٔ نشر متن کامل، فایل مشتق‌شده یا فقط شناسه و دستور تهیه ثبت خواهد شد. بستهٔ محلی B نیز بدون این بررسی، دارای مجوز نشر کامل فرض نمی‌شود؛ وضعیت نامعلوم صریح باقی می‌ماند.

خروجی و شرط تکمیل: PDF و Word مقاله، گزارش پاسخ موردبه‌مورد، خلاصهٔ دری، کد، تنظیمات، دادهٔ مجاز برای نشر، رکورد خام، ارزیابی، محیط اجرا، فهرست حقوق نشر و manifest بسته شوند. تمام ۶۷ مورد وضعیت نهایی و پیوند شاهد داشته باشند؛ مورد حل‌نشده با محدودیت یا دلیل روشن باقی بماند. تمام چهار شکل موجود بررسی و محفوظ باشند؛ کلید API و فایل محرمانه وارد بسته نشود. وابستگی: P7. مسئول: پژوهشگر و دستیار.

۵. طرح دقیق آزمایش تازه

۵.۱. هستهٔ بررسی کل خط لوله

برای هر پرسش، پنج وضعیت مجموعه ساخته می‌شود: پاک، هدفمند، نامرتبط، متن درست و هدفمند با برچسب پذیرفته‌شده. چهار حالت دفاع عبارت‌اند از: بدون دفاع، رتبه‌بندی مجدد، تصفیه و ترکیب. تعداد نامزد ۳۰، زمینهٔ نهایی ۵ و ترتیب شکست تساوی ثابت خواهد بود. بردارها یک بار تولید و منجمد می‌شوند. مدل متن‌ها را با شمارهٔ خنثی می‌بیند؛ نام حمله و برچسب اعتماد داخل prompt نمی‌رود.

در هسته، تمام ۶۴۰ متن پاک برچسب پذیرفته‌شده و تمام درج‌های پایه، شامل متن درست، برچسب ردشده دارند. تصفیه پیش از بازیابی، فقط متن دارای `verified=True` و اعتماد `high` یا `medium` را می‌پذیرد. در وضعیت برچسب پذیرفته‌شده، فقط همین دو فیلد متن هدفمند تغییر می‌کند. آزمون رد شاهد معتبر در ماژول جدا انجام می‌شود و این فرض هسته را تغییر نمی‌دهد.

در صورت تأمین ۶۴ پرسش، مجموعهٔ پاک ۶۴۰ متن دارد. هر وضعیت مثبت ۶۴ متن، یک متن به ازای هر هدف، اضافه می‌کند: ۶۴ از ۷۰۴ متن، یعنی حدود ۹٫۱ درصد مجموعهٔ نهایی. تمام اهداف پوشش دارند؛ این تنظیم، آزمایش تنش است و میزان آلودگی محیط واقعی تلقی نمی‌شود. طول پیشنهادی درج‌ها ۱۲۰ واژه است؛ متن‌ها باید رابطه، زمان و واحد را حفظ کنند و پرکردن طول نباید صحت کنترل درست را تغییر دهد.

برای مقایسه با B، تنظیم مولد دمای صفر، حداکثر ۶۴ توکن و عدم ذخیرهٔ پاسخ در سرویس خواهد بود. سه نوبت تولید تازه برای هر درخواست متفاوت اجرا می‌شود. کلید کش، شمارهٔ نوبت را در بر دارد: استفادهٔ مجدد میان شرایط دارای payload یکسان در همان نوبت مجاز است؛ عبور پاسخ نوبت اول به نوبت دوم یا سوم مجاز نیست. سه ارسال تازه، تضمین استقلال آماری پاسخ‌های سرویس نیست و پاسخ یکسان نیز حذف نمی‌شود.

۵.۲. کنترل مواجههٔ یکسان برای مولد

در هستهٔ قبلی، متن نامرتبط کمتر بازیابی می‌شد. بنابراین، تفاوت آن با حملهٔ هدفمند به‌تنهایی نشان نمی‌دهد که مولد در مواجههٔ برابر چگونه رفتار می‌کند. برای این پرسش، چهار زمینهٔ پنج‌قطعه‌ای ساخته می‌شود: پاک، هدفمند، نامرتبط و درست.

در هر پرسش، دو قطعهٔ شاهد کامل و دو قطعهٔ پاک دیگر ثابت می‌مانند. قطعهٔ پنجم در چهار وضعیت جایگزین می‌شود؛ در وضعیت پاک یک متن پاکِ نامرتبط و هم‌طول درج‌ها و در سه وضعیت دیگر درج متناظر است. محل این قطعه پیش از اجرا میان پنج رتبه توزیع متوازن و در چهار وضعیت هر پرسش ثابت می‌شود. متن‌های دیگر و ترتیب نسبی آن‌ها تغییر نمی‌کنند. اگر دو قطعه برای پوشش شواهد پرسش کافی نباشد، آن مورد پیش از انجماد از این پروتکل کنار گذاشته می‌شود.

در این ماژول، تصفیه و رتبه‌بندی مجدد اعمال نمی‌شود، همهٔ حملات حتماً به مولد می‌رسند و شاهد درست حذف نمی‌شود. شمار دقیق نمونه‌های واجد شرایط و زمینه‌های نهایی قبل از اجرا ثبت خواهد شد. این تنظیم مصنوعی و مکانیزمی، جدا از نتیجهٔ بازیابی واقعی گزارش می‌شود.

۵.۳. دوزهای ثابت‌هدف؛ ماژول تکمیلی پیشنهادی

برای پاسخ تازه به توصیهٔ بررسی شدت و تکرار، همان ۶۴ هدف در دوزهای ۱، ۲ و ۵ نسخهٔ یکسان نگه داشته می‌شوند. این ماژول پیش از اجرا انتخاب یا کنار گذاشته می‌شود و تصمیم آن به نتیجهٔ هسته وابسته نخواهد بود. دو دفاع بدون دفاع و رتبه‌بندی مجدد، با همان سه نوبت تولید بررسی می‌شوند؛ دوز یک از هسته تأمین می‌شود.

در مجموعهٔ ۶۴۰متنی، شمار درج‌ها ۶۴، ۱۲۸ و ۳۲۰ و سهم نهایی آن‌ها حدود ۹٫۱، ۱۶٫۷ و ۳۳٫۳ درصد است. شناسه‌ها متفاوت و متن نسخه‌ها یکسان است؛ ترتیب درج، حفظ نسخه‌های تکراری در نمایه و رفتار تساوی ثبت می‌شود. این آزمایش اثر تکرار همان متن را می‌سنجد، نه تنوع نگارش حمله و نه بازتولید خودکار آزمایش قدیمی.

۵.۴. سنجش کم‌هزینهٔ رد شاهد معتبر

یک آزمون حساسیت به خطای فرضی برچسب، فقط در سطح بازیابی و برای هر پرسش به‌صورت جفتی ساخته می‌شود. از دو شاهد پاک و پاسخ‌لازم، شاهد دارای شناسهٔ کوچک‌تر در ترتیب ثابت انتخاب می‌شود. در سه نسخهٔ جدا از نمایهٔ همان پرسش، همهٔ متن‌ها ثابت‌اند: شاهد منتخب پذیرفته است؛ همان شاهد رد می‌شود؛ یا به‌جای شاهد، یک غیرشاهد پاکِ ازپیش‌منتخب با همان قاعدهٔ شناسه رد می‌شود. تغییر Recall و حذف شاهد با و بدون تصفیه سنجیده می‌شود. این کار فراخوان مولد اضافه ندارد و هزینهٔ رد سند معتبر برای پوشش شاهد را روشن می‌کند؛ کاهش صحت پاسخ نهایی از آن استنتاج نمی‌شود.

۶. سقف محاسبات، درخواست و هزینه

شمار ردیف شرطی با شمار درخواست یکسان نیست. جدول زیر برای هدف ۶۴پرسشی و سه نوبت است. سقف فراخوان‌ها به ثابت‌ماندن طرح برچسب، پنهان‌بودن metadata در prompt و اثبات برابری payloadها وابسته است.

بخش	ردیف شرطی با سه نوبت	سقف درخواست تولید پس از حذف تکرار درون هر نوبت
هستهٔ بررسی کل خط لوله	۳٬۸۴۰	۱٬۵۳۶
مواجههٔ کنترل‌شدهٔ مولد	۷۶۸	۷۶۸
مجموع مسیر اصلی	۴٬۶۰۸	۳٬۳۰۴
دو دوز افزوده با اهداف ثابت	۷۶۸	۷۶۸
مجموع همراه ماژول دوز	۵٬۳۷۶	۳٬۰۷۲

علت سقف کمتر هسته این است که برای هر پرسش، حداکثر هشت payload متفاوت باقی می‌ماند: پاک، هدفمند، نامرتبط و درست، هر یک در دو حالت رتبه‌بندی. تصفیهٔ درج‌های ردشده به زمینهٔ پاک برمی‌گردد؛ درج هدفمند با برچسب پذیرفته‌شده نیز همان متن و زمینهٔ هدفمند متناظر را دارد. این

برابری باید از هش درخواست‌ها ثابت شود و فرض شفاهی کافی نیست. تعداد واقعی می‌تواند کمتر باشد؛ پیش از انجماد با سرشماری هش‌ها به دست می‌آید.

هر درخواست منطقی حداکثر سه تلاش شبکه، شامل ارسال اول و دو تلاش مجدد برای خطای گذرا، خواهد داشت. خطای دائمی، مدل متفاوت یا شکست هش باعث توقف می‌شود. سقف تلاش‌ها با ماژول دوز ۹٬۲۱۶ است؛ تلاش تکراری ممکن است هزینه داشته باشد. سقف توکن خروجی درخواست‌های موفق مسیر اصلی ۱۴۷٬۴۵۶ و با دوز ۱۹۶٬۶۰۸ است؛ مصرف واقعی از پاسخ سرویس ثبت می‌شود. درخواست‌های embedding، تعداد متن‌ها و توکن‌های آن جدا از تولید پاسخ شمرده می‌شوند؛ متن‌های یکسان از بردار ذخیره‌شده استفاده می‌کنند.

هزینهٔ پولی پس از شمارش توکن payloadهای منجمد و دریافت نرخ جاری همان مدل محاسبه می‌شود: هزینهٔ ورودی، خروجی، embedding و ذخیرهٔ احتیاط برای retry جدا می‌آید. در مرحلهٔ پلان، رقم پولی بدون نرخ و حجم تأییدشده وعده داده نمی‌شود. سقف هزینه پیش از اجرا در تنظیمات ثبت می‌شود؛ عبور از آن باعث توقف خواهد شد.

بار داوری انسانی نیز باید دیده شود. اگر U ترکیب متفاوت پرسش، زمینه و پاسخ و t میانگین دقیقهٔ بررسی هر مورد باشد، زمان دو ارزیاب تقریباً `2 × U × t / 60` ساعت، به‌علاوهٔ حل اختلاف‌هاست. برآورد از یک تمرین توسعه به دست می‌آید و پیش از تعهد به بررسی کامل اعلام می‌شود. کاهش هزینهٔ API با کش، تعداد داوری‌های لازم را خودبه‌خود تعیین نمی‌کند.

۷. ترتیب اجرا و تصمیم‌های وابسته

کار به شش نوبت اجرایی تقسیم می‌شود؛ عبور از هر نوبت به محصول آن وابسته است و تاریخ تقویمیِ بدون سنجش منابع وعده داده نمی‌شود.

نوبت	کار	شرط عبور
اول	P0 و شروع P1؛ جست‌وجوی آرشیو هم‌زمان P3	نسخه‌ها و حدود ادعا روشن؛ دفتر مرجع ایجاد شده باشد
دوم	تکمیل P1 و تعریف P2	ابهام‌های شناخته‌شده تعیین وضعیت؛ قواعد ارزیابی قابل اجرا باشد
سوم	بازتحلیل B، تصمیم A/A′ و اصلاح P4	تغییرات نسخه‌دار؛ کنترل توقف پیش از ارسال تأیید شود
چهارم	P5 و سرشماری درخواست و هزینه	اندازهٔ آزمون، مرجع، ماژول‌ها و تحلیل پیش از خروجی منجمد شوند

نوبت	کار	شرط عبور
پنجم	P6 و داوری در دسترس، سپس P7	خروجی خام کامل یا خطاهای مستند؛ محاسبات قابل ردیابی باشد
ششم	P8 و کنترل نهایی	متن، اشکال، جدول‌ها، گزارش پاسخ و بستهٔ شواهد با هم سازگار باشند

چهار موضوع ممکن است به همکاری بیرون از اجرای تخنیکی نیاز داشته باشد: آرشیو تاریخی خارج از مخزن، مرجع صلاحیت واقعی برچسب‌ها، دسترسی به ارزیابان انسانی و سقف هزینهٔ اجرای تازه. نبود هر کدام، به ساخت شاهد جایگزین یا ادعای تکمیل آن منجر نمی‌شود. کارهای مستقل ادامه می‌یابد و دامنهٔ محصول با وضعیت واقعی آن مورد تنظیم می‌شود.

۸. معیار پایان و محصول قابل ارسال

پایان کار زمانی اعلام می‌شود که نتایج نهایی از دادهٔ خام دوباره ساخته شوند، تمام ردیف‌های ملاحظه پاسخ مستند داشته باشند و هیچ ادعا از سطح شواهد خود فراتر نرود. معیار، رسیدن به عدد دلخواه برای صحت یا کاهش حمله نیست؛ نتیجهٔ نامطلوب نیز باید بدون حذف گزارش شود.

بستهٔ نهایی شامل مقالهٔ انگلیسی PDF و Word، گزارش رسمی دری، پاسخ موردبه‌مورد به متخصص و مواد قابل نشر بازتولید خواهد بود. وضعیت آرشیو A، انسانی یا خودکاربودن ارزیابی، تازگی آزمون C، شمار درخواست‌ها و محدودیت اعتماد در همان اسناد اصلی روشن نوشته می‌شود.

این پلان، مرحلهٔ ریسرچ را به کارهای اجرایی وصل می‌کند. اولین اقدام عملی پس از این مرحله، ساخت نسخهٔ کار تازه و تکمیل دفتر مرجع‌هاست؛ آزمایش تازه پس از آماده‌شدن معیار و انجماد پروتکل آغاز خواهد شد.

اسناد مبنا

- گزارش مرحلهٔ ریسرچ و ممیزی‌ها در پوشهٔ `research_phase`؛ به‌ویژه `Research_Stage_Report_FA.md`، `gap_matrix.json` و `artifact_audit/audit_report.json`.
- بررسی دیتای اصلی در `repo_audit/original_data_audit.json` و بررسی هم‌پوشانی در `repo_audit/cross_study_overlap.json`.
- شواهد اختلاف مرجع در `reference_source_checks.json`؛ سند رسمی USAAF: راهنمای آرشیو ملی، بخش‌های 18.1 و 18.5.
- نسخهٔ بررسی‌شدهٔ مخزن: RAG-Security-Lab، commit ثابت.