پاسخ به گزارش بررسی تخنیکی مقالهٔ امنیت در سیستم‌های RAG

امر صاحب محترم، سلام و احترام.

بر مبنای گزارش ۹صفحه‌ای شما، روش، دیتا، ارزیابی و حدود استنتاج مقاله بازبینی شد. نسخهٔ همراه برای ارزیابی مجدد اصلاحات ارائه می‌شود. در این پاسخ، کار اجراشده از محدودیتی که فقط روشن و مستند شده است جدا بیان می‌شود. جدول تفصیلی پیگیری ٦٧ مورد و لینک کد، دیتا و پاسخ‌های خام نیز همراه است.

۱. معماری واقعی و استفاده از مدل مولد — بخش ۳.۱

تفاوت سیستم انتخاب جملهٔ تاریخی A با سیستم مولد روشن شده است. نتیجه‌های اصلی نسخهٔ جاری بر مطالعهٔ C استوارند که واقعاً از `gpt-4.1-mini-2025-04-14` و بردارهای API مدل `text-embedding-3-small` استفاده کرده است: بازیابی cosine، انتخاب ۳۰ نامزد و زمینهٔ نهایی پنج‌قطعه‌ای. سه نوبت تازه، **۲۵۵۹ پاسخ مولد متمایز** برای ۸۵۳ درخواست متفاوت تولید کرده و به **۵۲۰۸ سطر شرایط و نوبت** متصل شده‌اند. تمام پاسخ‌ها توقف عادی دارند؛ تغییر مدل یا جایگزینی مدل محلی ثبت نشده است.

معماری پیشنهادی، کد فعلی workbench و اجرای گزارش‌شدهٔ تاریخی یکسان فرض نشده‌اند. در جایی که سند تصمیم تاریخی دربارهٔ انتخاب یا غیرفعال‌بودن یک جزء در دسترس نبود، دلیل تازه به‌عنوان نیت گذشتهٔ نویسنده نوشته نشده است.

۲. ساخت دیتا و انتشار متن حمله — بخش‌های ۳.۲ و ۳.۳

ورودی‌های فعلی A شامل ۲۲۴ سند، ۲۲۵ قطعه، ۳٦۴ پرسش و ۱۰۴ حمله قابل دسترس و ردیابی‌اند. منشأ ٥٦ سند قبلی و ١٦٨ مشاهدهٔ WDI و ساخت دو صورت سؤال برای هر مشاهده، مستند شده است. ۳۳٦ پرسش WDI به‌عنوان ۳۳٦ واقعیت مستقل تلقی نشده‌اند. بازسازی ورودی، تأیید مستقل حقیقت تمام ٥٦ سند قبلی یا تمام مرجع‌های تاریخی نیست.

برای ٦٢ ،C پرسش تازه و ٦٢ اهداکننده با فایل منبع، ٦٢٠ متن پاک و درج‌های هدفمند، نامرتبط و مرجع‌سازگار ثبت شده‌اند. شناسه، پاسخ مرجع، مقدار هدف، متن کامل درج، برچسب‌ها و لینک شاهد در فایل‌ها موجود است. درج‌های متناظر ۱۲۰ واژه دارند. کنترول مواجههٔ جدا نیز اجرا شده است تا نتیجه فقط به تفاوت بازیابی درج هدفمند و نامرتبط وابسته نماند. این کنترول‌ها آزمایش قالب‌های ثبت‌شده‌اند و واقع‌گرایی تمام حملات ممکن را ثابت نمی‌کنند.

۳. روش ارزیابی و بررسی دستی معنایی — بخش ۳.۴ و مرحلهٔ ۶.۳

تعریف محاسباتی تطبیق عدد، نارمل‌سازی، پاسخ مختصر، امتناع، نفی، قید و پاسخ مختلط روشن و کد اجرایی ارزیابی ارائه شده است. قاعدهٔ قدیمی B بر تمام ۱۲۸۰ سطر بازحساب شد و در معیارهای بررسی‌شده اختلافی با آرشیف پیدا نشد؛ این تأیید محاسبهٔ همان قاعده است، نه تأیید معنای هر پاسخ.

نویسنده بررسی دستی معنایی **۷۲ مورد پرسش–زمینه–پاسخ** را گزارش کرده و یافته‌های آن در مقاله ثبت شده است: ۳۲ مورد B و ۳۲ مورد C در نمونهٔ اصلی، همراه هشت مورد تشخیصی B که جدا تحلیل شده‌اند.

نتیجه نسبت به شواهد منبع	تعداد در ۶۴ مورد اصلی
ادعای پاسخ سازگار با منبع	۴۱
ادعای پاسخ مخالف منبع	۱۶
امتناع کامل، بدون ادعای پاسخ	۳
نامشخص	۴

در مکمل تشخیصی، دو پاسخ عددی همراه با امتناع متعارض ثبت شده است. نمونه‌های مشخص شامل پاسخ Koufax با «۱۹۷۲» و سپس «UNKNOWN»، سؤال مبهم بازیگر و سال جایزه، قید «بیش از ۳۰۰۰»، پاسخ بدون شاهد کافی در زمینهٔ مدل و شاهد پاک جایگزین برای سال ۱۹۴۳ است. گزارش تجمیعی نویسنده و یادداشت‌های کمکی با منشأ خود نگهداری شده‌اند؛ از آن‌ها ضریب توافق بین ارزیابان، دقت تمام پاسخ‌ها یا فیصد موفقیت معنایی کل حملات استخراج نشده است.

۴. تفسیر نتیجه‌ها و تحلیل شکست — بخش‌های ۳.۵ و ۳.۸

بازیابی شاهد، ورود درج به زمینه، تولید مقدار هدف، پیشگیری و بازگشت مقدار مرجع جدا گزارش شده‌اند. در C، شاخص خودکار انتخاب مقدار هدف در حالت هدفمند بدون دفاع **۳۷٫۶ فیصد** و در کنترول نامرتبط **صفر** است؛ با رتبه‌بندی مجدد به **۲۱٫۰ فیصد** می‌رسد. هم‌زمان، انتخاب مقدار مرجع در مجموعهٔ پاک از **۵۹٫۱ فیصد به ۴۵٫۷ فیصد** کاهش می‌یابد. بنابراین، کاهش تولید هدف به‌تنهایی حفظ کارکرد پاسخ را ثابت نمی‌کند.

در کنترول مواجهه، هر دو شاهد لازم و درج متناظر در زمینه حاضرند؛ شاخص هدفمند **۱۶٫۱ فیصد** و نامرتبط صفر است. این مقایسه دربارهٔ همان زمینه‌های ساخته‌شده است. تفاوت آن با بازیابی معمولی فقط به حضور شاهد نسبت ارائه نشده، زیرا ترکیب زمینه‌ها نیز فرق دارد. فایل موارد شکست و نمونه‌های قابل ردیابی همراه‌اند. ارقام مذکور شاخص‌های خودکارند و به نام نرخ قطعی پذیرش معنایی ادعای غلط معرفی نشده‌اند.

۵. برچسب اعتماد و هزینهٔ رد شاهد مشروع — بخش ۳.۶

شرط پذیرش برچسب و مرجع تخصیص آن روشن شده است: برچسب‌ها در این آزمایش توسط سازندهٔ دیتا فراهم شده‌اند. تغییر متناظر برچسب همان متن هدفمند به حالت پذیرفته‌شده، اثر حفاظتی فیلتر را از بین می‌برد. این، آزمایش مرز فرضی اعتماد است؛ اجرای سیستم عملیاتی احراز اصالت یا نفوذ واقعی به صلاحیت یک اداره ادعا نشده است.

آزمایش بازیابیِ جداگانه نیز نشان می‌دهد که رد یک شاهد لازم، پوشش تمام شواهد را از ۳۹ از ۶۲ به صفر می‌رساند؛ کنترول رد یک متن غیرشاهد همان ۳۹ از ۶۲ را حفظ می‌کند. در این ماژول پاسخ تازهٔ مولد تولید نشده، بنابراین هزینهٔ پاسخ نهایی از آن استنباط نشده است.

۶. بودجه و تکرار با اهداف ثابت — بخش ۳.۷

ماژول تازه با همان ۶۲ هدف و یک، دو و پنج نسخهٔ یکسان درج اجرا شده است. شاخص خودکار هدفمند بدون دفاع به‌ترتیب **۳۷٫۶ فیصد، ۵۳٫۸ فیصد و ۹۶٫۸ فیصد** است. تعداد هدف در این مقایسه ثابت می‌ماند؛ تکرار می‌تواند شاهد پاک را از زمینهٔ محدود بیرون براند. شرایط، تعداد نسخه، سهم نهایی درج و پاسخ‌های خام ثبت شده‌اند. این آزمایش، بازاجرای آرشیف تکرار تاریخی A معرفی نشده است.

۷. حدودی که همچنان باید صریح بمانند

آرشیف تاریخی A: آرشیف دقیق ۲۱۸۴۰سطری اصلی و ۳۰۱۶سطری تکرار در جست‌وجوی ثبت‌شده بازیابی نشده است. ورودی و کد فعلی در دسترس است، اما آن‌ها را جای نسخهٔ دقیق اجرای گذشته معرفی نکرده‌ایم. تنظیمات فعلی workbench نیز با بودجه‌های گزارش‌شدهٔ تاریخی یکسان نیست؛ ساختن دوبارهٔ همان شمار سطر، هویت همان اجرا را ثابت نمی‌کند. اجرای کد فعلی یک آزمایش تازه خواهد بود. A در نسخهٔ جاری زمینهٔ تاریخی است و بازتولید نتیجه‌های اصلی C به آن آرشیف گمشده وابسته نیست.

مرجع‌های B: پنج مورد مبهم، شش مورد نیازمند اصلاح و ده مقدار هدف با نادرستیِ اثبات‌نشده گزارش شده‌اند؛ این دسته‌ها هم‌پوشانی دارند. امتیازهای قدیمی خاموش تغییر نکرده‌اند. تحلیل حساسیت ۵۰موردی جدا و پسینی است. پاسخ قدیمی برای سؤال بازنویسی‌شده تولید نشده است؛ بنابراین اصلاح معنای سؤال با نمره‌دادن همان پاسخ قدیمی به سؤال تازه جبران نمی‌شود. B برای تشخیص و بازتحلیل نگه داشته شده و مبنای ادعای تأییدشدهٔ موفقیت معنایی نیست.

تعمیم: C شامل ۵۷ پرسش سال و پنج پرسش جمعیت، یک snapshot مولد و حمله‌های قالبی است. نتیجه به همین شرایط محدود شده است؛ تکرار همین پرسش‌ها شمار نمونهٔ مستقل را افزایش نمی‌دهد. آزمایش چندمدلی یا دامنه‌های تازه در این تحویل انجام‌شده معرفی نشده‌اند. این محدودسازی مطابق بخش‌های ۳.۵ و ۴.۵ گزارش شماست.

۸. اصلاح ساختار و تحویل شواهد — بخش‌های ۴، ۵ و ۶

چکیده، روش، نتایج، بحث و نتیجه‌گیری با معماری فعال و شواهد واقعی هماهنگ شده‌اند. مطالعهٔ اصلی و ماژول‌های تکمیلی تفکیک شده‌اند. چهار شکل قبلی حفظ و شکل C افزوده شده است؛ عنوان‌های PDF سیاه‌اند.

کد، دیتا، متن حمله، تنظیمات، زمینه‌ها، پاسخ‌های خام، معیارها، محیط اجرا و منشأ دیتا در GitHub قرار دارند. کنترول مستقلِ بدون API، هش‌ها، ۲۵۵۹ پاسخ، ۵۲۰۸ سطر، ۱۹۶ سلول خلاصه و ۴۸ شمار انتقال جفتی را تطبیق می‌دهد. اجرای موفق آن در GitHub نیز ثبت شده است. معلومات سخت‌افزار مشتری موجود است؛ سخت‌افزار داخلی سرویس مدل معلوم و ادعا نشده است.

درخواست ارزیابی مجدد: خواهشمندم نسخهٔ اصلاح‌شده را همراه فایل‌های شاهد بررسی فرمایید. کارهای اجراشده و محدودیت‌های باقی‌مانده در این پاسخ و جدول ۶۷موردی جدا آمده‌اند؛ پوشش جدول به معنی بسته‌شدن همهٔ محدودیت‌ها یا تضمین آمادگی نشر نیست.

با احترام

لینک‌های اصلی تحویل

- مقالهٔ اصلاح‌شده
- گزارش تفصیلی تطبیق اصلاحات
- کد آزمایش مولد C
- راهنمای بررسی مستقل شواهد
- فهرست جداگانهٔ تمام لینک‌های خواسته‌شده