گزارش تطبیق اصلاحات علمی و تخنیکی مقالهٔ امنیت سیستم‌های RAG

عنوان مقالهٔ مورد بررسی:

Security of Retrieval-Augmented Generation Against Targeted Knowledge-Base Poisoning

مبنای گزارش: ملاحظات متخصص، گزارش ریسرچ، پلان اجرایی و فایل‌های شاهد هر مطالعه.

رسید نسخه: زمان دقیق ساخت و هش فایل‌های مبنا در رسید همراه ثبت شده است.

ماهیت سند: گزارش وضعیت واقعی تطبیق اصلاحات. آماده‌بودن ابزار، فورم یا متن کاری با تکمیل آزمایش و داوری یکسان محسوب نمی‌شود.

۱. ارزیابی عمومی پس از تطبیق اصلاحات

نقد اصلی متخصص به اعتبار استنتاج مقاله مربوط بود: سیستم انتخاب جمله با یک سیستم مولد واقعی تفاوت دارد؛ شمار و ساختار دیتا برای بازتولید کافی نیست؛ حضور مقدار مرجع یا مقدار مهاجم در پاسخ، معنای پاسخ را به‌تنهایی مشخص نمی‌کند؛ و کارکرد فیلتر به اعتبار برچسب ورودی وابسته است. پاسخ به این نقدها به تغییر نثر محدود نشد. هویت مطالعه‌ها تفکیک گردید، دیتا و محاسبات موجود ممیزی شد و مرجع‌های مسئله‌دار آشکار گردید. مطالعهٔ تازهٔ C نیز با ۲۵۵۹ فراخوانی واقعی در سه نوبت تکمیل و از آرشیف منطبق تحلیل شد.

مهم‌ترین حاصل این مرحله، روشن‌شدن حدود شواهد است. مطالعهٔ مولد B واقعاً پاسخ مدل دارد و محاسبات قاعدهٔ قدیمی آن قابل بازحساب است. در عین حال، ممیزی منبع نشان داد که تمام مرجع‌ها و مقادیر موسوم به غلط از یک درجهٔ اعتبار برخوردار نیستند. بنابراین، تأیید محاسبات عددی را نمی‌توان تأیید صحت معنایی همهٔ نتایج دانست. این تفاوت در مقالهٔ کاری، ارزیاب و فورم داوری اعمال شده است.

مرز شواهد اکنون روشن است: C مبنای اصلی نتیجه‌های آزمایشی است؛ B برای بازتحلیل و تشخیص خطای مرجع نگه داشته شده و A فقط زمینهٔ تاریخی است. بررسی دستی معنایی ۷۲موردی نویسنده در بخش دهم گزارش شده است. نبود آرشیف دقیق تاریخی و محدودیت تعمیم همچنان در حدود ادعای مربوط به خود بیان می‌شود؛ این دو محدودیت به نام رفع تجربی معرفی نشده‌اند.

۲. دامنهٔ بررسی و روش تهیهٔ این گزارش

مبنای پیگیری، ٦٧ مورد استخراج‌شده از گزارش متخصص است. برای هر مورد، اقدام اجراشده، مسیر شاهد، وضعیت فعلی و کار باقیمانده در جدول جدا ثبت شده است. عبارت «اجراشده در مستندسازی» فقط تکمیل توضیح یا ثبت تصمیم را نشان می‌دهد؛ به معنی برطرف‌شدن هر محدودیت تجربی نیست. موارد مشروط، توصیه‌شده و الزامی با همان قوت درخواست اصلی نگه داشته شده‌اند. پوشش ٦٧ مورد، نمرهٔ علمی یا گواهی آمادگی نشر نیست.

این گزارش از آرشیف و کد محلی می‌خواند و خود هیچ درخواست مدل یا داوری انسانی ایجاد نمی‌کند. نتیجهٔ C تنها هنگامی وارد متن می‌شود که تحلیل ذخیره‌شده، رسید تکمیل و هش آرشیف پاسخ‌ها منطبق باشد. تاریخ ساخت و هش فایل‌های مبنا در رسید گزارش ثبت می‌شود. هر عدد نتیجه باید به مطالعه و نسخهٔ معیار مربوط باشد؛ جمع‌کردن سطرهای چند مطالعه به‌عنوان حجم نمونهٔ مستقل پذیرفته نشده است.

۳. معماری و هویت مطالعه‌ها

اشکال نسخهٔ قبلی فقط نام یک جزء نبود. اگر پاسخ نهایی از میان جمله‌های موجود انتخاب شود، نتیجه دربارهٔ همان بازیابی و انتخاب جمله است. نام‌بردن مدل یا پایگاه برداری در طرح پیشنهادی، فعال‌بودن آن در اجرای تاریخی را ثابت نمی‌کند. برای همین، دفتر مطالعه و دفتر ادعا از هم‌پوشانی نسخه‌ها جلوگیری می‌کنند.

بخش شواهد	آنچه واقعاً در دسترس است	حد ادعای مجاز
A تاریخی	مقاله، ورودی‌های اصلی و شرح اجرای گزارش‌شده	رقم‌های تاریخی به‌عنوان گزارش پیشین؛ بازتولید تازهٔ خروجی ادعا نمی‌شود.
کد فعلی ریپو	نسخهٔ مشخص workbench و فایل‌های دیتا	شرح همان نسخه؛ یکسان‌بودن آن با runtime اصلی فرض نمی‌شود.
آزمایش تشخیصی	آرشیف/خلاصهٔ جدا با ۱۰۹۲ سطر	جانشین ۲۱۸۴۰ سطر اصلی یا ۳۰۱٦ سطر تکرار نیست.
B مولد	٦۴ پرسش، ۱۲۸۰ سطر شرط و ۳۷٦ پاسخ یکتای واقعی	شواهد مولد برای همان مدل، دیتا و قاعدهٔ ارزیابی؛ اکنون مادهٔ توسعه و بازتحلیل است.
C پیگیری	طرح ٦۲جفتی با کنترول‌های از پیش تعیین‌شده	نتیجه فقط از آرشیف واقعی خودش و با حدود شاخص‌های خودکار گزارش می‌شود.

شرح مقاله اکنون میان معماری پیشنهادی و اجزای فعال تفاوت می‌گذارد. دلیل تاریخی غیرفعال‌بودن هر جزء، در جایی که سند تصمیم وجود ندارد، نامعلوم باقی گذاشته شده است. توجیه امروز به‌عنوان تصمیم گذشته نوشته نشده است.

۴. دیتای تاریخی و مسئلهٔ بازتولید

وجود ریپوی RAG-Security-Lab و دیتای آن تأیید شد. در commit مبنای بررسی، `6f76858df91277e4b962ee94b4286a25cfe08d4d`، ورودی‌های اصلی شامل ۲۲۴ سند، ۲۲۵ قطعه، ۳۶۴ پرسش و ۱۰۴ حمله قابل ردیابی است. بازسازی ورودی‌ها با اسکریپت جداگانه در مرحلهٔ ریسرچ، ۵۶ سند قبلی و ۱۶۸ مشاهدهٔ WDI و ساخت ۳۳۶ پرسش از دو قالب برای هر مشاهده را بررسی کرده است. بنابراین، عبارت مطلق «کد و دیتای اصلی موجود نیست» دقیق نبود و در بازنویسی اصلاح شد.

با این حال، دسترسی به ورودی با دسترسی به نتیجهٔ همان اجرا فرق دارد. جست‌وجوی ثبت‌شده شاخه، commit، درخت فایل، release و مواد قابل دسترس مرتبط را بررسی کرد. آرشیف ۲۱۸۴۰سطری اجرای اصلی، آرشیف ۳۰۱۶سطری تکرار و نسخهٔ منطبق کد و تنظیمات مؤثر بازیابی نشد. این نتیجه تنها دربارهٔ حدود همان جست‌وجو است؛ به معنی نبود فایل در هر محل یا ازبین‌رفتن آن نیست.

تصمیم عملی، حفظ نتیجهٔ تاریخی با شرح وضعیت و پرهیز از ادعای بازتولید تازه است. اگر آرشیف اصلی بعداً به دست آید، نخست باید شناسهٔ اجرا و هش‌ها تطبیق داده شود؛ سپس بازنمره‌دهی و در صورت امکان بازاجرای همان نسخه انجام شود. اجرای نسخهٔ تازه با شمار سطر یکسان، در صورت نیاز A′ نام خواهد گرفت و تاریخچه را به‌طور خودکار بازتولید نمی‌کند. ماژول تکرار C نیز یک آزمایش تازه است و جای آرشیف تاریخی معرفی نمی‌شود.

۵. ممیزی مرجع و اعتبار مقدار حمله در B

برای تمام ۶۴ پرسش B فایل پرسش، رابطه، شاهد، قید و مقدار هدف ساخته شد. حاصل ممیزی دستیار نسبت به منبع آرشیف‌شده چنین است:

محور بررسی	تعداد	معنا
مرجع پذیرفته نسبت به رابطهٔ منبع	53	سازگاری با منبع معین؛ تصدیق مستقل همهٔ واقعیت‌های بیرونی نیست.
مرجع مبهم	5	دامنه، تاریخ، گردکردن یا رابطه جواب یکتا نمی‌دهد.
مرجع نیازمند اصلاح	6	رابطه یا انتساب مرجع با پرسش دقیق سازگار نیست.

محور بررسی	تعداد	معنا
مقدار هدف مخالف رابطهٔ دقیق منبع	54	شاهد برای غلط‌بودن در همان رابطه موجود است.
غلط‌بودن مقدار هدف ثابت نشده	10	وجود قید یا ابهام اجازهٔ طبقه‌بندی قطعی موفقیت واقعی حمله را نمی‌دهد.

سه سطر نخست، وضعیت مرجعِ همان ۶۴ پرسش را تقسیم می‌کند؛ دو سطر آخر، محور جداگانهٔ اعتبار مقدار هدف است. این دو محور روی همان موارد هم‌پوشانی دارند و تعدادهای آنان نباید به‌عنوان پرسش‌های مستقل با هم جمع شود.

این نتیجه بر استنتاج اثر مستقیم دارد. برای نمونه، سال تأسیس و سال تجدید سازمان USAAF یک رابطه نیست. «بیش از ۲۳۰» تمام مقادیر بزرگ‌تر از ۲۳۰ را نفی نمی‌کند. عدد ۳۱۱ در نام یک گروه، یک کمیت قابل جمع یا شمارش نیست. همچنان ممکن است رقم یک منبع دربارهٔ شهر، تور یا شخص دیگری باشد. در چنین حالت‌ها، تطبیق عددی به تنهایی کفایت نمی‌کند و بزرگ‌ترکردن عدد مرجع دلیل اثبات غلط‌بودن مقدار تازه نیست.

هیچ مرجع، پاسخ خام یا نمرهٔ قدیمی به‌صورت خاموش تغییر دیتا نشد. نتیجهٔ کامل ۶۴موردی حفظ گردید. افزون بر آن، یک تحلیل حساسیت پسینی برای ۵۰ مورد کمّیِ هم‌راستا با رابطهٔ منبع آماده شد. در این زیرمجموعه، تولید عدد هدف در شرط هدفمند بدون دفاع ۲۵ مورد و با رتبه‌بندی مجدد ۱۴ مورد بود؛ این ارقام از ۳۴ و ۱۷ مورد در مجموعهٔ کامل جدا است. این زیرمجموعه بعد از ممیزی دیتای دیده‌شده انتخاب شده و آزمایش تازهٔ دست‌نخورده یا برآورد تأییدشدهٔ ASR معنایی نامیده نمی‌شود.

بازبینی جامع مستقل ۵۶ سند پیشین و تمام واقعیت‌های تاریخی A هنوز تکمیل نیست. فایل‌سازی B این کار را به‌طور خودکار انجام نداده است. در بستهٔ پیگیری، این تفاوت با وضعیت باز باقی می‌ماند.

۶. بازتحلیل پاسخ‌ها و محدودیت معیار خودکار

قاعدهٔ قدیمی B بر تمام 1280 سطر دوباره اجرا شد و در معیارهای بررسی‌شده 0 اختلاف با جدول آرشیف‌شده یافت شد. این نتیجه، قابلیت بازحساب همان قاعده را نشان می‌دهد. به دلیل استفادهٔ مجدد از پاسخ‌های یکسان، ۱۲۸۰ سطر شرط فقط 376 پاسخ یکتای واقعی دارد. تعداد سطر شرط، تعداد فراخوانی مدل و شمار پرسش مستقل سه مقدار متفاوت است.

نسخهٔ تازه، تولید مختصر و سخت‌گیرانهٔ عدد را از حضور عدد در یک جمله جدا می‌کند. نفی، نقل قول، قید، امتناع جمله‌ای و حضور هم‌زمان عدد و UNKNOWN پرچم بازبینی می‌گیرد. میان ۳۷۶ پاسخ یکتا، قاعدهٔ قدیمی ۵۱ مورد دارای مقدار هدفِ تنها شمرده بود؛ شاخص انتخاب سخت‌گیرانه ۴۷ مورد را مشخص

می‌کند. شمار امتناع لفظی قدیمی ۴۱ بود، در حالی که تشخیص زبان امتناع ۴۶ مورد نشان داد. این تغییرها تعریف شاخص را تغییر می‌دهد؛ عدد تازه نباید «صحت معنایی تصحیح‌شده» نامیده شود.

در شرط حملهٔ هدفمند بدون دفاع، ۳۴ پاسخ دارای مقدار هدف بر اساس قاعدهٔ قدیمی، در شاخص سخت‌گیرانه به ۳۱ مورد می‌رسد. با رتبه‌بندی مجدد، ارقام متناظر ۱۷ و ۱۶ است. نام و مخرج هر شاخص در جدول‌ها جدا درج شده است. نفی‌کردن یک مقدار نادرست یا گفتن «این مقدار در سند آمده، ولی قابل تأیید نیست» با پذیرفتن آن یکسان نیست؛ تشخیص نهایی این تفاوت به بررسی معنایی واقعی نیاز دارد.

همچنان سه محور از هم جدا شده است: بازیابی هر دو شاهد لازم؛ پاسخِ هم‌مقدار با مرجع؛ و پذیرش یک ادعای واقعاً غلط. پشتیبانی از زمینه نیز دو معنا دارد: پاسخ ممکن است از متن مسمومِ ارائه‌شده پشتیبانی شود، اما از شاهد پاک معتبر پشتیبانی نشود. این دو حالت در دستورالعمل داوری ستون مستقل دارد.

۷. مطالعهٔ تازهٔ C: طرح و وضعیت مشاهده‌شده

مطالعهٔ C برای پاسخ به مقایسه‌ای تازه طراحی شد. استفادهٔ دوباره از B به‌عنوان آزمایش دست‌نخورده، پس از مشاهده و ممیزی پاسخ‌های آن، توجیه نداشت. انتخاب C از snapshot ثابت بخش عمومی validation در HotpotQA انجام می‌شود. شناسه‌ها و عنوان‌های تمام ۱۲۸ مورد قبلی، شامل پرسش‌های آزمایش و اهداکنندگان، از قاب تازه کنار گذاشته شدند. این اقدام، استقلال از موارد قبلی پروژه را در حدود کنترول‌های ثبت‌شده تقویت می‌کند؛ استقلال از پیش‌آموزش مدل یا اعتبار آزمایش مخفی رسمی را ثابت نمی‌کند.

در پلان اولیه ۶۴ جفت پیشنهاد شده بود. بررسی واحدها پیش از هر خروجی تازه نشان داد که طبقهٔ کلی «شمار» می‌تواند فاصله، رتبه، عدد ترتیبی و تعداد موجودیت‌ها را مخلوط کند. بنابراین، دامنه به ۶۲ جفتِ هم‌واحد محدود شد: ۵۷ جفتِ سال تقویمی و ۵ جفتِ جمعیت با تاریخ معین. این تغییر پیش از مشاهدهٔ پاسخ C ثبت شده است؛ انتخاب نمونه بر اساس بهترشدن نتیجه نبوده است. از ۱۹۲ نامزد بررسی‌شده توسط دستیار، ۱۳۵ مورد نسبت به شاهد منبع پذیرفته، ۳۸ مورد کنار گذاشته و ۱۹ مورد حل‌نشده ثبت شد. این بررسی، داوری انسانی نامیده نمی‌شود.

در طبقه‌های نهایی، ۱۱۴ نامزد سال و ۱۱ نامزد جمعیت واجد شرط بودند. جفت‌سازی مجاور بر اساس ترتیب هش، همهٔ ۱۱۴ مورد سال و ۱۰ مورد جمعیت را به کار برد. آخرین مورد جمعیت در همان ترتیب، بدون همتای مجاور باقی ماند و به‌عنوان ذخیرهٔ استفاده‌نشده ثبت شد؛ این مورد پس از مشاهدهٔ نتیجه کنار گذاشته نشده است. پرسش‌ها و مرجع‌های اصلی بازنویسی نشده‌اند. هر ۱۲۴ مورد منتخب با منبع ثابت تطبیق شد و ۱۲۴۰ عنوان زمینه در میان آنان مشترک نیست؛ تفاوت عنوان، استقلال کامل معنایی یا خانوادهٔ منبع را اثبات نمی‌کند.

هستهٔ طرح ۶۲۰ متن پاک، پنج شرط و چهار روش دفاع را دربر می‌گیرد. در هر شرط مثبت ۶۲ متن افزوده می‌شود و نسبت آلودگی ۶۲ از ۶۸۲، یعنی ۹٫۰۹ فیصد است. این نسبت با پوشش تمام هدف‌ها همراه است و سناریوی فشار آزمایشگاهی محسوب می‌شود. کنترول نامرتبط، همان مقدار تعیین‌شده را برای رابطهٔ اهداکننده به کار می‌برد؛ کنترول بی‌ضرر مقدار مرجع پرسش هدف را دارد. طول متن درج‌شده ۱۲۰ واژه تثبیت شده است. در آزمایش زمینهٔ کنترول‌شده، چهار متن اصلی ثابت می‌ماند و فقط یک جایگاه با متن درج‌شده عوض می‌شود؛ هر دو شاهد لازم نگه داشته می‌شوند. ماژول دوزهای ۱، ۲ و ۵ نیز پوشش همان هدف‌ها را ثابت نگه می‌دارد.

مدل مولد مقرر `gpt-4.1-mini-2025-04-14` و مدل بردارساز `text-embedding-3-small` است. سه نوبت فراخوانی تازه، از استفادهٔ مجدد پاسخ یک payload درون همان نوبت جدا می‌شود. این سه نوبت شمار پرسش‌های مستقل را از ۶۲ بیشتر نمی‌کند. میانگین ابتدا درون هر پرسش و سپس میان پرسش‌ها گرفته می‌شود. دامنهٔ کمینه و بیشینهٔ نوبت‌ها توصیف تغییر مشاهده‌شده است و فاصلهٔ اطمینان جمعیت معرفی نمی‌شود.

وضعیت خوانده‌شده در ساخت این گزارش: نتیجه از تحلیل خروجی‌های خام تکمیل‌شده و دارای هش منطبق خوانده شد.

مشخصهٔ آرشیف واقعی	مقدار
پرسش / نوبت	3 / 62
سطر شرط برنامه‌ریزی‌شده	5208
payload یکتا در هر نوبت	853
پاسخ منطقی محفوظ / فراخوانی منطقی برنامه‌ریزی‌شده	2559 / 2559
پایان عادی / پاسخ بریده / پایان دیگر در فراخوانی‌های یکتا	0 / 0 / 2559
توکن ورودی / خروجی مولد، فقط فراخوانی‌های متمایز	7974 / 1786392
هزینهٔ تعهدشدهٔ محافظه‌کارانه، USD؛ مبلغ صورتحساب نیست	0.7295299000000001
داوری انسانی ثبت‌شده در تحلیل C	0

نتیجهٔ خودکار اصلی: فیصد انتخاب عددی سخت‌گیرانهٔ مقدار هدف، با میانگین سه نوبت درون هر پرسش؛ این جدول ASR معنایی تأییدشده نیست.

شرط	دفاع	انتخاب هدف	انتخاب مرجع	هر دو شاهد	دامنهٔ نوبت‌های هدف
clean	none	۰٫۰۰ فیصد	۵۹٫۱۴ فیصد	۶۲٫۹۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
clean	rerank	۰٫۰۰ فیصد	۴۵٫۷۰ فیصد	۳۵٫۴۸ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
clean	filter	۰٫۰۰ فیصد	۵۹٫۱۴ فیصد	۶۲٫۹۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
clean	filter_rerank	۰٫۰۰ فیصد	۴۵٫۷۰ فیصد	۳۵٫۴۸ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
targeted	none	۳۷٫۶۳ فیصد	۴۸٫۹۲ فیصد	۵۴٫۸۴ فیصد	۳۵٫۴۸ فیصد تا ۳۸٫۷۱ فیصد
targeted	rerank	۲۰٫۹۷ فیصد	۳۹٫۷۸ فیصد	۳۳٫۸۷ فیصد	۲۰٫۹۷ فیصد تا ۲۰٫۹۷ فیصد
targeted	filter	۰٫۰۰ فیصد	۵۹٫۱۴ فیصد	۶۲٫۹۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
targeted	filter_rerank	۰٫۰۰ فیصد	۴۵٫۷۰ فیصد	۳۵٫۴۸ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
unrelated	none	۰٫۰۰ فیصد	۵۷٫۵۳ فیصد	۵۸٫۰۶ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
unrelated	rerank	۰٫۰۰ فیصد	۴۶٫۲۴ فیصد	۳۷٫۱۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
unrelated	filter	۰٫۰۰ فیصد	۵۹٫۱۴ فیصد	۶۲٫۹۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
unrelated	filter_rerank	۰٫۰۰ فیصد	۴۵٫۷۰ فیصد	۳۵٫۴۸ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
benign	none	۰٫۰۰ فیصد	۹۸٫۳۹ فیصد	۵۴٫۸۴ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
benign	rerank	۰٫۰۰ فیصد	۷۴٫۱۹ فیصد	۳۳٫۸۷ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
benign	filter	۰٫۰۰ فیصد	۵۹٫۱۴ فیصد	۶۲٫۹۰ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد
benign	filter_rerank	۰٫۰۰ فیصد	۴۵٫۷۰ فیصد	۳۵٫۴۸ فیصد	۰٫۰۰ فیصد تا ۰٫۰۰ فیصد

شرط	دفاع	انتخاب هدف	انتخاب مرجع	هر دو شاهد	دامنهٔ نوبت‌های هدف
accepted_label	none	۳۷٫۶۳ فیصد	۴۸٫۹۲ فیصد	۵۴٫۸۴ فیصد	۳۵٫۴۸ فیصد تا ۳۸٫۷۱ فیصد
accepted_label	rerank	۲۰٫۹۷ فیصد	۳۹٫۷۸ فیصد	۳۳٫۸۷ فیصد	۲۰٫۹۷ فیصد تا ۲۰٫۹۷ فیصد
accepted_label	filter	۳۷٫۶۳ فیصد	۴۸٫۹۲ فیصد	۵۴٫۸۴ فیصد	۳۵٫۴۸ فیصد تا ۳۸٫۷۱ فیصد
accepted_label	filter_rerank	۲۰٫۹۷ فیصد	۳۹٫۷۸ فیصد	۳۳٫۸۷ فیصد	۲۰٫۹۷ فیصد تا ۲۰٫۹۷ فیصد

در هستهٔ بدون دفاع، شاخص انتخاب هدف در شرط هدفمند ۳۷٫۶۳ فیصد و در شرط نامرتبط ۰٫۰۰ فیصد است. با رتبه‌بندی مجدد، مقدار هدفمند به ۲۰٫۹۷ فیصد می‌رسد. اما مواجههٔ متن درج‌شده برابر نیست: درج متناظرِ هدفمند در ۱۰۰٫۰۰ فیصد و درج متناظرِ نامرتبط در ۰٫۰۰ فیصد زمینه‌ها حضور دارد. پس اختلاف هسته، اثر کل خط لولهٔ بازیابی و پاسخ را نشان می‌دهد؛ به‌تنهایی اثر محتوا را در مواجههٔ برابر جدا نمی‌کند.

کاهش تولید هدف نیز به معنی افزایش هم‌زمان کیفیت همهٔ پاسخ‌ها نیست. در مجموعهٔ پاک، انتخاب سخت‌گیرانهٔ مقدار مرجع از ۵۹٫۱۴ فیصد بدون دفاع به ۴۵٫۷۰ فیصد با رتبه‌بندی مجدد رسیده است. این هزینهٔ قالب پاسخ/تطبیق مرجع باید کنار کاهش مقدار هدف دیده شود؛ هیچ‌یک هنوز صحت معناییِ داوری‌شده توسط انسان نیست. تمام سلول‌های اصلی این اجرای تکمیل‌شده پاسخ عادی دارند و سلول نامعلومِ ناشی از نقص اجرا گزارش نشده است.

کنترول مواجهه: دو شاهد کامل و دو متن غیرشاهد ثابت‌اند؛ فقط یک جایگاه متن، درون هر پرسش، تغییر می‌کند.

جایگاه کنترول‌شده	انتخاب هدف	انتخاب مرجع	هر دو شاهد	مواجهه با درج متناظر
clean	۰٫۰۰ فیصد	۷۹٫۵۷ فیصد	۱۰۰٫۰۰ فیصد	۰٫۰۰ فیصد
targeted	۱۶٫۱۳ فیصد	۸۲٫۲۶ فیصد	۱۰۰٫۰۰ فیصد	۱۰۰٫۰۰ فیصد
unrelated	۰٫۰۰ فیصد	۸۴٫۴۱ فیصد	۱۰۰٫۰۰ فیصد	۱۰۰٫۰۰ فیصد
benign	۰٫۰۰ فیصد	۱۰۰٫۰۰ فیصد	۱۰۰٫۰۰ فیصد	۱۰۰٫۰۰ فیصد

در این ماژول، هر دو نوع درج هدفمند و نامرتبط حتماً ارائه می‌شوند و هر دو شاهد لازم نیز در تمام موارد باقی می‌مانند. شاخص هدف در شرط هدفمند ۱۶٫۱۳ فیصد و در نامرتبط ۰٫۰۰ فیصد است. این مقایسه، مشکل نابرابری مواجههٔ هسته را برای همین زمینه‌های ساخته‌شده رفع می‌کند. با این حال، تفاوت میان

۳۷٫۶۳ فیصد هسته و ۱۶٫۱۳ فیصد کنترول را نمی‌توان فقط به حفظ شاهد نسبت داد؛ متن‌های غیرشاهد، ترتیب و روش ساخت زمینه نیز میان دو ماژول فرق دارد.

تکرار با پوشش هدف ثابت: دوز، شمار نسخه‌های یک متن یکسان برای هر هدف است.

نسخه برای هر هدف	دفاع	انتخاب هدف	انتخاب مرجع	هر دو شاهد
1	none	۳۷٫۶۳ فیصد	۴۸٫۹۲ فیصد	۵۴٫۸۴ فیصد
1	rerank	۲۰٫۹۷ فیصد	۳۹٫۷۸ فیصد	۳۳٫۸۷ فیصد
2	none	۵۳٫۷۶ فیصد	۳۱٫۱۸ فیصد	۴۵٫۱۶ فیصد
2	rerank	۳۳٫۸۷ فیصد	۳۲٫۸۰ فیصد	۲۹٫۰۳ فیصد
5	none	۹۶٫۷۷ فیصد	۱٫۶۱ فیصد	۰٫۰۰ فیصد
5	rerank	۵۶٫۹۹ فیصد	۱۰٫۷۵ فیصد	۶٫۴۵ فیصد

با افزایش نسخه‌های یکسان، هم رقابت بازیابی و هم ترکیب جایگاه‌های زمینه تغییر کرده است. در دوز پنج بدون دفاع، نبود هر دو شاهد در زمینه با افزایش شاخص هدف همراه است؛ این همراهی، آزمایش تنوع حمله یا جداسازی علّیِ «تکرار» از حذف شاهد نیست. متن‌ها عمداً تکراری‌اند و قطعه‌های یکسان حذف نشده‌اند. نتیجه به این قالب، همین مدل و همین مجموعه محدود می‌ماند.

تحلیل انتقال جفتی نیز افت خالص را توضیح می‌دهد. در مجموعِ سلول‌های سه نوبت، از 70 رویداد اولیهٔ معیارِ «مواجهه به‌اضافهٔ انتخاب هدف»، 48 مورد پس از رتبه‌بندی مجدد دیگر معیار را ندارد؛ تنها 20 مورد به انتخاب مقدار مرجع می‌رسد و 17 رویداد تازه در خارج از مجموعهٔ اولیه ایجاد می‌شود. این شمارها سلول‌های پرسش–نوبت‌اند، نه همان تعداد پرسش مستقل یا خطای معنایی تأییدشده. بنابراین، پیشگیری، بازیابی مقدار مرجع و تولید هدف تازه باید جدا گزارش شوند.

تمام معیارها، مقایسه‌های جفتی و موارد شکست در `analysis/study_c/` محفوظ است. گروه‌های از پیش تعریف‌شده و انتخاب نمونهٔ توضیحی با هش ثابت نگهداری شده‌اند؛ مثالِ مطلوب جای مجموعهٔ کامل خطاها را نگرفته است.

۸. برچسب اعتماد و دامنهٔ دفاع

فیلتر آزمایش، اسناد دارای `verified=True` و برچسب high یا medium را می‌پذیرد. در دیتای پایه، تمام متن‌های پاک پذیرفته و تمام درج‌های جدید، حتی درج بی‌ضرر، رد می‌شوند. پس کاهش حمله در این شرط به فرض درست‌بودن برچسب‌ها وابسته است. این طراحی، سیستم احراز هویت سند یا روند نهادی تأیید محتوا را پیاده نمی‌کند.

شرط برچسب پذیرفته، متن و شناسهٔ همان درج هدفمند را نگه می‌دارد و فقط صفات اعتماد را عوض می‌کند. این مقایسه می‌تواند وابستگی دفاع به metadata ورودی را نشان دهد. از آن نمی‌توان وقوع نفوذ واقعی، دورزدن کنترول دسترسی یا شکست امضای دیجیتال را نتیجه گرفت. در نبود شاهد مرجع صلاحیت‌دار، برچسب به سازندهٔ دیتای آزمایش نسبت ارائه شده است.

جلوگیری از تولید مقدار هدف نیز با بازگشت پاسخ درست برابر نیست. ممکن است دفاع مقدار مهاجم را حذف کند، اما شاهد لازم را هم از دست بدهد و مدل امتناع یا عدد دیگری تولید کند. به همین دلیل، پیشگیری، بازگشت مقدار مرجع و خطای تازه در مقایسه‌های جفتی جدا تعریف شده‌اند. نتیجهٔ صفر در یک ستون فقط به همان معیار، نمونه، مدل و فرض برچسب مربوط است.

حساسیت به رد اشتباه شاهد مشروع:

برچسب‌گذاری در آزمایش جدا	شمار دارای هر دو شاهد	مخرج	فیصد
all_accepted	39	62	۶۲٫۹۰ فیصد
support_rejected	0	62	۰٫۰۰ فیصد
distractor_rejected	39	62	۶۲٫۹۰ فیصد

این آزمایش فقط بازیابی را اندازه می‌گیرد. در هر پرسش، یک شاهد لازم با قاعدهٔ شناسهٔ ثابت رد شده و با رد یک متن غیرشاهد مقایسه شده است. از دست‌رفتن شرط «هر دو شاهد» پس از حذف یک شاهد لازم، پیامد ساختاری همین سنجه است؛ صحت پاسخ مدل یا دسترسی به شاهد معادل را اندازه نمی‌گیرد. برای این ماژول هیچ فراخوانی تازهٔ بردارسازی یا تولید پاسخ انجام نشده و هزینهٔ پاسخ نهایی از آن استنتاج نشده است.

۹. کنترول تمامیت اجرا و نگهداری مواد قبلی

در runner تازه، طراحی پیش از بردارسازی و زمینه‌ها و درخواست‌ها پیش از تولید پاسخ منجمد می‌شود. کد و دیتای مؤثر، تنظیمات، payload و فایل‌های مرتبط با هش تطبیق می‌گردد. کنترول پیش از هر ارسال و ادامهٔ اجرا، شامل مسیر کش خالی، اعمال می‌شود. تغییر ورودی یا درخواست باید پیش از تماس با سرویس اجرای مرحله را متوقف کند. کنترول مدل برگشتی، ذخیرهٔ پاسخ خام، تعداد تلاش محدود، سقف هزینه و توقف خطای دائمی نیز جدا تعریف شده است.

آزمایش‌های آفلاین این مسیر از دیتای ساختگی و ارسال‌کنندهٔ ساختگی استفاده می‌کنند. گذشتن آن‌ها شاهد رفتار کد است و آزمایش واقعی C محسوب نمی‌شود. همان‌گونه، دیتای ساختگی آزمایش در جدول نتیجه یا داوری انسانی وارد نمی‌شود. محیط مشتری و نسخهٔ کتابخانه‌ها ثبت شده، اما سخت‌افزار

سرویس مدل و محیط مجهول تاریخی با مشخصات میزبان فعلی پر نشده است.

ثبت تکمیلی محیط محلی در زمان اجرا، پردازندهٔ INTEL(R) XEON(R) PLATINUM 8573C، سه پردازندهٔ منطقی قابل مشاهده، سهمیهٔ دو هسته و سقف حافظهٔ ۸ GiB را نشان می‌دهد. این مشاهده با تاریخ خود در protocol/client_hardware_observation.json نگهداری می‌شود و اعلامِ پیش از انجماد معرفی نشده است. بردارسازی و تولید متن در سرویس دوردست انجام شده؛ مشخصات این میزبان جای سخت‌افزار نامعلوم سرویس API یا محیط تاریخی را نمی‌گیرد.

یک بررسی محاسباتی جداگانه نیز زنجیرهٔ هش، شناسه‌های پاسخ سرویس، ترتیب دو انجماد و سه نوبت، مصرف توکن و دفتر هزینه را با فایل‌های خام تطبیق داد. این بررسی بدون واردکردن ارزیاب و تحلیل‌گر اصلی، 196 سلول خلاصه و 48 شمار انتقال جفتی را دوباره محاسبه کرد و اختلاف ثبت نشد. تمام 244 فایل مبنای قبلی نیز بدون تغییر باقی است. این شاهدِ تمامیت و بازحساب محاسبه است؛ بازتولید بیرونی یا داوری معنایی انسان محسوب نمی‌شود. رسید آن در protocol/POSTRUN_QA.json موجود است.

چهار شکل قبلی حفظ شده‌اند: فلوچارت خط لوله، شکل صحت مقدار پاسخ تاریخی، شکل موفقیت حملهٔ تاریخی و نمودار نتیجهٔ مولد B. هش بایت‌های اصلی در دفتر حفظ اشکال موجود است. شکل تاریخی با شرح تاریخی و محدودیت خود باقی می‌ماند؛ نتیجهٔ تازه نباید روی آن نوشته شود. ساخت مقالهٔ جدید باید درج هر چهار شکل را نیز بررسی کند، زیرا حفظ فایل به تنهایی به معنی درج صحیح در Word یا PDF نیست.

۱۰. یافته‌های بررسی دستی معنایی نویسنده

نویسنده انجام بررسی دستی معنایی ۷۲ مورد پرسش–زمینه–پاسخ را اعلام و یافته‌های آن را ارائه کرده است. نمونهٔ اصلی شامل ۳۲ مورد از B و ۳۲ مورد از C است؛ هشت مورد تشخیصی B جدا بررسی شده‌اند. این بررسی پسینی و توسط نویسندهٔ آگاه از مطالعه انجام شده است. روش جاری، مطالعهٔ توافق بین ارزیابان یا برآورد دقت کل سیستم نیست؛ دامنهٔ ارزیابی جاری همان بررسی موردی نویسنده است.

مبنای قضاوت، معنای ادعا برای موجودیت، رابطه، تاریخ، واحد و قید سؤال بود. شواهد کامل مرجع از زمینهٔ واقعاً ارائه‌شده به مدل جدا دیده شد. اظهار عدد، نقل عدد، نفی آن و امتناع از پاسخ یک نتیجه محسوب نشد. دفتر انتخاب نمونه و یادداشت‌های کمکی دستیار با منشأ خود حفظ شده‌اند؛ جدول زیر خلاصهٔ یافته‌هایی است که نویسنده ارائه کرده و جدول نمره‌های فردی ساختگی برای انسان تولید نشده است.

نتیجهٔ بررسی نسبت به شواهد منبع	تعداد در نمونهٔ اصلی
پاسخ سازگار با منبع	۴۱

نتیجهٔ بررسی نسبت به شواهد منبع	تعداد در نمونهٔ اصلی
پاسخ مخالف منبع	۱۶
امتناع کامل، بدون ادعای پاسخ	۳
نامشخص	۴
مجموع	۶۴

هشت مورد تشخیصی با نمونهٔ اصلی یکجا به‌عنوان فیصد دقت حساب نمی‌شوند؛ این موارد با پرچم‌های خطا انتخاب شده‌اند. در دو مورد، پاسخ هم عدد را اظهار و هم از پاسخ مبتنی بر شواهد امتناع کرده است.

یافتهٔ نخست، پاسخ Koufax است که 1972 را بیان و سپس پاسخ براساس متن‌های ارائه‌شده را UNKNOWN اعلام می‌کند؛ معیار تطبیق عدد این تعارض را از بین نمی‌برد. یافتهٔ دوم، ابهام شخص در سؤال بازیگر دو سریال است: مرجع 1994 شخص مورد نظر annotation را دنبال می‌کند، در حالی که شواهد موجود تعبیر دیگری با 2013 را پشتیبانی می‌کند. یافتهٔ سوم، حفظ قید «بیش از ۳۰۰۰» است؛ این عبارت، شمار دقیق نیست و به‌تنهایی ۳۰۱۷ را غلط ثابت نمی‌کند. یافتهٔ چهارم، پاسخ‌های سازگار با مرجع است که در زمینهٔ واقعی مدل شاهد کافی ندارند. یافتهٔ پنجم، شاهد پاک جایگزین Operation Ladbroke برای 1943 است، با اینکه یکی از شواهد علامت‌گذاری‌شده حضور ندارد.

این یافته‌ها نشان می‌دهند صحت معنایی، پشتیبانی از زمینه و پوشش شواهد annotation باید جدا گزارش شوند. تمام ۱۸۸ نقل‌قول یادداشت‌های همراه با متن منبع یا پاسخ دقیق تطبیق ارائه شده‌اند. گزارش نویسنده در manual_review/author_reported_findings.json و شناسه‌ها، پاسخ‌ها، شواهد و منشأ یادداشت‌های کمکی در assistant_review/ قابل بررسی‌اند. یافته‌های نمونه به‌عنوان نرخ پذیرش معنایی ادعای غلط مهاجم در تمام آزمایش تعمیم ارائه نشده‌اند.

۱۱. بازنویسی مقاله و نحوهٔ ارائه به متخصص

نسخهٔ کاری مقاله، شرح معماری واقعی، دسترسی ورودی‌های تاریخی، وضعیت آرشیف، ممیزی مرجع B، تحلیل حساسیت و حدود برچسب اعتماد را بازنویسی می‌کند. رقم قدیمی با رقم بازتحلیل‌شده در یک جدول بدون نام نسخه جایگزین نشده است. چکیده و نتیجه باید روشن سازد که کدام یافته به مطالعهٔ مولد مربوط است و کدام نمودار تنها نتیجهٔ گزارش‌شدهٔ تاریخی را نگه می‌دارد.

ارجاع‌ها و کتابنامه اصلاح شده‌اند. نسخهٔ تحویل شامل مقاله، گزارش، جدول ۶۷ مورد و بستهٔ قابل بازحساب شواهد است. متن نتیجه، تولید عدد هدف را با فیصد تأییدشدهٔ پذیرش معنایی ادعای غلط یکسان معرفی نمی‌کند. گزارش بررسی دستی نویسنده و محدودیت نمونه نیز همراه همان نسخه ارائه

می‌شود.

۱۲. تصمیم عملی دربارهٔ پنج نقد باقی‌مانده

نقد	اقدام این نسخه	حدی که حفظ شده است
اعتبار تفسیر معنایی	بررسی دستی معنایی نویسنده بر ۷۲ مورد با یافته‌ها و نمونه‌های مشخص گزارش شد.	فیصد موفقیت معنایی برای کل پاسخ‌ها و توافق ارزیابان ادعا نشده است.
عیب واقعی بعضی مرجع‌های B	B به شاهد تشخیصی پسینی محدود شد؛ نتیجهٔ اصلی بر C و کنترول‌های آن استوار است. ۵ ابهام، ٦ اصلاح و ۱۰ مقدار با نادرستی ثابت‌نشده با هم‌پوشانی خود حفظ شدند.	خطای مرجع با حذف خاموش یا تغییر معنای سؤال اصلاح‌شده معرفی نمی‌شود؛ حساسیت ۵۰موردی جای مخرج اصلی را نمی‌گیرد.
آرشیف تاریخی A	A فقط به‌عنوان زمینهٔ تاریخی نگه داشته شد؛ ورودی‌های موجود و حدود جست‌وجو منتشر می‌شوند.	بازتولید خروجی تاریخی ادعا نمی‌شود و C جانشین اجرای A نامیده نشده است.
دسترسی مستقل به شواهد	کد، دیتا، پاسخ‌های خام، زمینه‌ها، بردارها، هش‌ها و دستور بررسی بدون API در ریپو قرار می‌گیرند.	بررسی صحت محاسبات و تمامیت فایل با تأیید مستقل همهٔ حقایق منبع یکسان نیست.
دامنهٔ تعمیم	نتیجه به ٦۲ پرسش، یک snapshot مدل، حملهٔ قالبی و ماژول‌های ثبت‌شده محدود شد.	ادعای تعمیم به مدل‌های دیگر، همهٔ موضوع‌ها یا استقرار نهادی حذف شده است.

برای متخصص، یک لینک GitHub به نسخهٔ مقاله، گزارش، یافته‌های معنایی و مسیر اجرای بررسی شواهد ارائه می‌شود. پیشرفت این نسخه، ارائهٔ یافته‌های موردی و امکان بررسی مستقل محاسبات است؛ ارقام آزمایش منجمد برای متفاوت‌نشان‌دادن نتیجه تغییر نکرده‌اند. توسعهٔ بعدی می‌تواند منبع، نوع سؤال و مدل بیشتری را بیازماید، اما چنین آزمایشی در این نسخه انجام‌شده معرفی نمی‌شود.

ضمیمهٔ الف. نمای پیگیری درخواست‌های متخصص

جدول کامل با اقدام، شاهد، معیار تکمیل و کار باقیمانده در `Implementation_Progress_67_FA.csv` و نسخهٔ JSON همراه موجود است. نمای زیر برای مرور سریع است. واژهٔ «اجراشده» در یک سطر تنها به همان اقدام محدود است و وضعیت سایر سطرها را نمی‌بندد.

شناسه	موضوع درخواست	وضعیت تطبیق
3.1.1	معماری واقعاً اجراشده	اجراشده در مستندسازی

شناسه	موضوع درخواست	وضعیت تطبیق
3.1.2	دلیل انتخاب Hashing و TF-IDF	تاحدی؛ دلیل تاریخی نامعلوم
3.1.3	علت غیرفعال‌بودن اجزای پیشنهادی	تاحدی؛ دلیل تاریخی نامعلوم
3.1.4	حداقل یک آزمایش با LLM واقعی، مشروط به ادعای مولد	آزمایش‌های واقعی B و C مستند
3.1.5	بدیل محدودسازی عنوان و ادعاها	اصلاح ادعا در نسخهٔ کاری
3.2.1	فهرست منابع اصلی	ورودی‌های موجود ردیابی شده
3.2.2	انتخاب ۱۶۸ مشاهده و خانواده‌های WDI	بازسازی ورودی انجام‌شده
3.2.3	شِمای اسناد، قطعه‌ها، پرسش‌ها و پاسخ‌ها	ورودی‌های موجود ردیابی شده
3.2.4	چگونگی ساخت ۳۶۴ پرسش	تاحدی؛ منشأ دستی محدود
3.2.5	اعتبار پرسش و پاسخ مرجع	A ردیابی شد؛ صحت مستقل مرجع‌های آن باز است
3.2.6	وضعیت بازبینی اسناد و برچسب‌های قبلی	تاحدی؛ بازبینی پیشین ثابت نیست
3.2.7	لینک ردیابی‌پذیر سند، قطعه و پرسش	ورودی‌های موجود ردیابی شده
3.2.8	وابستگی صورت‌های پرسش در عدم‌قطعیت	قاعدهٔ تحلیل پیاده‌شده
3.3.1	تمام ۱۰۴ پرسش هدف تاریخی	ورودی‌های موجود ردیابی شده
3.3.2	پاسخ درست هر هدف تاریخی	هدف‌های A ردیابی شد؛ اعتبار معنایی مستقل باز است
3.3.3	مقدار نادرست مورد نظر مهاجم	هدف‌های A ردیابی شد؛ اعتبار معنایی مستقل باز است
3.3.4	متن کامل همهٔ حملات تاریخی	ورودی‌های موجود ردیابی شده
3.3.5	شناسهٔ منبع متصل به هر حمله	ورودی‌های موجود ردیابی شده
3.3.6	برچسب‌های اعتماد هر شرط حمله	فرض اعتماد روشن؛ سیستم عملیاتی اجرا نشده
3.3.7	روند تولید حمله	تاحدی؛ منشأ دستی محدود
3.3.8	طول، ساختار و شباهت متن حمله	ویژگی درج‌ها مستند و کنترول‌های متناظر اجرا شده
3.4.1	تعریف اجرایی ارزیابی و مثال	کد و مثال اجرایی آماده

شناسه	موضوع درخواست	وضعیت تطبیق
3.4.2	نارمل‌سازی عدد، سال، واحد و اعشار	کد و مثال اجرایی آماده
3.4.3	بازنمره‌دهی اجرایی در برابر مرجع	B بازتحلیل شد؛ خروجی تاریخی A باز است
3.4.4	نمونه‌های صحیح، غلط و مبهم ارزیابی	بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده
3.4.5	مقایسه با نمونهٔ داوری انسانی در صورت امکان	بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده
3.4.6	تفکیک بازیابی، انتخاب پاسخ و صحت مولد	محورهای ارزیابی جدا شده
3.5.1	تحلیل جداگانهٔ بازیابی، پاسخ و موفقیت حمله	محورهای ارزیابی جدا شده
3.5.2	تحلیل افزایش بازیابی و کاهش صحت	تحلیل خودکار B و C انجام‌شده
3.5.3	تحلیل خطا فراتر از ارقام نهایی	تحلیل خودکار B و C انجام‌شده
3.5.4	تفسیر محدود صفر ASR	اصلاح ادعا در نسخهٔ کاری
3.6.1	شیوهٔ تخصیص برچسب اعتماد	فرض اعتماد روشن؛ سیستم عملیاتی اجرا نشده
3.6.2	مرجع صلاحیت تأیید سند	فرض اعتماد روشن؛ سیستم عملیاتی اجرا نشده
3.6.3	احراز اصالت، صلاحیت و ثبت رویداد metadata	فرض اعتماد روشن؛ سیستم عملیاتی اجرا نشده
3.6.4	محدودیت فیلتر در بحث و نتیجه	اصلاح ادعا در نسخهٔ کاری
3.6.5	آزمایش تغییر غیرمجاز metadata در صورت امکان	فرض اعتماد روشن؛ سیستم عملیاتی اجرا نشده
3.7.1	انتخاب اهداف در هر بودجه	نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم
3.7.2	تفکیک پوشش هدف، شمار موفقیت و نرخ هدف‌های حمله‌شده	قاعدهٔ تحلیل پیاده‌شده
3.7.3	توصیهٔ دوزهای متعدد با اهداف ثابت	ماژول تازه اجرا و تحلیل شده
3.7.4	نقش و مقدار seed	نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم
3.8.1	شاهد درستِ بازیابی‌شده و پاسخ غلط	تحلیل خودکار B و C انجام‌شده
3.8.2	مواجهه با حمله بدون موفقیت	تحلیل خودکار B و C انجام‌شده

شناسه	موضوع درخواست	وضعیت تطبیق
3.8.3	جلوگیری از حمله بدون بازگشت پاسخ صحیح	تحلیل خودکار B و C انجام‌شده
3.8.4	اثر تغییر برچسب بر نتیجهٔ حمله	شرط برچسب B و C تحلیل شده
3.8.5	تحلیل تغییر رفتار بر اثر تکرار	شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا
3.8.6	پروتکل مستقل و کامل آزمایش تکرار	شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا
4.1	چکیدهٔ متناسب با روش و محدودیت	بازنویسی و بازسازی از شواهد موجود انجام‌شده
4.2	روش قابل بازسازی	بازنویسی و بازسازی از شواهد موجود انجام‌شده
4.3	تفکیک نتایج اصلی و تکمیلی	بازنویسی و بازسازی از شواهد موجود انجام‌شده
4.4	بحث بر پایهٔ خطا و محدودیت metadata	بازنویسی و بازسازی از شواهد موجود انجام‌شده
4.5	نتیجه‌گیری محدود به شواهد	اصلاح ادعا در نسخهٔ کاری
5.1	کد کامل آماده‌ساختن تا ارزیابی	کد ادامه و بازتحلیل موجود
5.2	اسناد، قطعه‌ها، پرسش‌ها و مرجع‌ها	ورودی‌های موجود ردیابی شده
5.3	متن، شناسه، هدف و مقدار حملات	ورودی‌های موجود ردیابی شده
5.4	تنظیمات و seedهای کامل	نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم
5.5	خروجی خام هر پرسش، دفاع و دوز	B/C محفوظ؛ آرشیف تاریخی A بازیابی نشده
5.6	ارزیاب اجرایی Recall، صحت، ASR و مواجهه	کد ادامه و بازتحلیل موجود
5.7	محیط نرم‌افزار و سخت‌افزار	کنترول اجرا و محیط C مستند
5.8	منشأ، استخراج، تاریخ دسترسی و بررسی منبع	منشأ نسخه‌دار ثبت؛ تصدیق جامع بیرونی باز است
5.9	طرح پیشنهادی در برابر معماری اجراشده	اجراشده در مستندسازی
5.10	مستند مکمل برچسب و تکرار	شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا
5.11	محدودیت نشر و حقوق استفاده	تاحدی؛ شرایط استفاده باید حفظ شود
6.1	آغاز با روش و اجزای واقعی	اجراشده در مستندسازی

شناسه	موضوع درخواست	وضعیت تطبیق
6.2	سپس محاسبه و بازتولید نتایج موجود	B بازتحلیل شد؛ خروجی تاریخی A باز است
6.3	سپس بهبود ارزیابی و عدم‌قطعیت	بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده
6.4	سپس آزمایش مولد و مکمل متناسب	مطالعهٔ C اجرا و تحلیل شده
6.5	در پایان بازنویسی بر اساس نتایج تأییدشده	بازنویسی و بازسازی از شواهد موجود انجام‌شده

ضمیمهٔ ب. مسیر شواهد برای بررسی

مسیر نسبت به ریشهٔ اصلاحات	محتوا
baseline/claims_registry.json و study_registry.json	هویت مطالعه و مرز هر ادعا
history/reproducibility_decision.json و bounded_search_results.json	تصمیم بازتولید و حدود جست‌وجوی آرشیف
reference_audit/B_reference_cards_v2.json	فایل مرجع، رابطه، قید و مقدار هدف هر پرسش B
evaluation/B_reanalysis_v2_summary.json	تعداد سطر و پاسخ یکتا، تطبیق قاعدهٔ قدیمی و تشخیص تازه
manual_review/author_reported_findings.json	گزارش تجمیعی نویسنده از۷۲مورد و یافته‌های معنایی
manual_review/author_reported_findings.json	گزارش نویسنده از بررسی معنایی ۷۲ مورد و یافته‌های نمونه
protocol/study_c_protocol.json	انتخاب ۶۲جفتی، سؤال تحقیق، کنترول، تکرار، توقف و تحلیل
runner/run_study.py و test_run_study.py	کنترول تمامیت و ارسالِ نسخهٔ تازه و آزمایش آفلاین
/analysis/study_c	خروجی واقعی تحلیل، مقایسه‌های جفتی و موارد شکست، در صورت وجود رسید تکمیل
assistant_review/selection_freeze.json و pass1_input_*.json	شناسهٔ نمونه‌ها و متن کامل پرسش، پاسخ و شواهد بررسی‌شده
study_c/retrieval_label_stress_summary.json	آزمایش جداگانهٔ بازیابی در برابر خطای فرضی برچسب، بدون تولید پاسخ
history/figure_preservation_registry.json	شناسه و هش چهار شکل محفوظ
manuscript/Working_Manuscript_v2.md	متن کاریِ قابل بازسازی از شواهد موجود