# گزارش تطبیق اصلاحات علمی و تخنیکی مقالهٔ امنیت سیستم‌های RAG

**عنوان مقالهٔ مورد بررسی:**

Security of Retrieval-Augmented Generation Against Targeted Knowledge-Base Poisoning

**مبنای گزارش:** ملاحظات متخصص، گزارش ریسرچ، پلان اجرایی و فایل‌های شاهد هر مطالعه.

**تاریخ ساخت به وقت UTC: ۲۰۲۶/۱۰/۳۱**، ساعت ۰۷:۲۲

**ماهیت سند:** گزارش وضعیت واقعی تطبیق اصلاحات. آماده‌بودن ابزار، فورم یا متن کاری با تکمیل آزمایش و داوری یکسان محسوب نمی‌شود.

## ۱. ارزیابی عمومی پس از تطبیق اصلاحات

نقد اصلی متخصص به اعتبار استنتاج مقاله مربوط بود: سیستم انتخاب جمله با یک سیستم مولد واقعی تفاوت دارد؛ شمار و ساختار داده برای بازتولید کافی نیست؛ حضور مقدار مرجع یا مقدار مهاجم در پاسخ، معنای پاسخ را به‌تنهایی مشخص نمی‌کند؛ و کارایی فیلتر به اعتبار برچسب ورودی وابسته است. پاسخ به این نقدها به تغییر نثر محدود نشد. هویت مطالعه‌ها تفکیک گردید، داده و محاسبات موجود ممیزی شد و مرجع‌های مسئله‌دار آشکار گردید. مطالعهٔ تازهٔ C نیز با ۳٬۵۵۹ فراخوانی واقعی در سه نوبت تکمیل و از آرشیو منطبق تحلیل شد.

مهم‌ترین حاصل این مرحله، روشن‌شدن حدود شواهد است. مطالعهٔ مولد B واقعاً پاسخ مدل دارد و محاسبات قاعدهٔ قدیمی آن قابل بازحساب است. در عین حال، ممیزی منبع نشان داد که تمام مرجع‌ها و مقادیر موسوم به غلط از یک درجهٔ اعتبار برخوردار نیستند. بنابراین، تأیید محاسبات عددی را نمی‌توان تأیید صحت معنایی همهٔ نتایج دانست. این تفاوت در مقالهٔ کاری، ارزیاب و فورم داوری اعمال شده است.

مرز شواهد اکنون روشن است: C مبنای اصلی نتیجه‌های آزمایشی است؛ B برای بازتحلیل و تشخیص خطای مرجع نگه داشته شده و A فقط زمینهٔ تاریخی است. بررسی دستی معنایی ۷۲موردی نویسنده در بخش دهم گزارش شده است. نبود آرشیو دقیق تاریخی و محدودیت تعمیم همچنان در حدود ادعای مربوط به خود بیان می‌شود؛ این دو محدودیت به نام رفع تجربی معرفی نشده‌اند.

## ۲. دامنهٔ بررسی و روش تهیهٔ این گزارش

مبنای پیگیری، ٦٧ مورد استخراج‌شده از گزارش متخصص است. برای هر مورد، اقدام اجراشده، مسیر شاهد، وضعیت فعلی و کار باقیمانده در جدول جدا ثبت شده است. عبارت «اجراشده در مستندسازی» فقط تکمیل توضیح یا ثبت تصمیم را نشان می‌دهد؛ به معنی برطرف‌شدن هر محدودیت تجربی نیست. موارد مشروط، توصیه‌شده و الزامی با همان قوت درخواست اصلی نگه داشته شده‌اند. پوشش ٦٧ مورد، نمرهٔ علمی یا گواهی آمادگی نشر نیست.

این گزارش از آرشیو و کد محلی می‌خواند و خود هیچ درخواست مدل یا داوری انسانی ایجاد نمی‌کند. نتیجهٔ C تنها هنگامی وارد متن می‌شود که تحلیل ذخیره‌شده، رسید تکمیل و هش آرشیو پاسخ‌ها منطبق باشد. تاریخ ساخت و هش فایل‌های مبنا در رسید گزارش ثبت می‌شود. هر عدد نتیجه باید به مطالعه و نسخهٔ معیار مربوط باشد؛ جمع‌کردن ردیف‌های چند مطالعه به‌عنوان حجم نمونهٔ مستقل پذیرفته نشده است.

## ۳. معماری و هویت مطالعه‌ها

اشکال نسخهٔ قبلی فقط نام یک جزء نبود. اگر پاسخ نهایی از میان جمله‌های موجود انتخاب شود، نتیجه دربارهٔ همان بازیابی و انتخاب جمله است. نام‌بردن مدل یا پایگاه برداری در طرح پیشنهادی، فعال‌بودن آن در اجرای تاریخی را ثابت نمی‌کند. برای همین، دفتر مطالعه و دفتر ادعا از هم‌پوشانی نسخه‌ها جلوگیری می‌کنند.

| بخش شواهد | آنچه واقعاً در دسترس است | حد ادعای مجاز |
|---|---|---|
| A تاریخی | مقاله، ورودی‌های اصلی و شرح اجرای گزارش‌شده | رقم‌های تاریخی به‌عنوان گزارش پیشین؛ بازتولید تازهٔ خروجی ادعا نمی‌شود. |
| کد فعلی مخزن | نسخهٔ مشخص workbench و فایل‌های داده | شرح همان نسخه؛ یکسان‌بودن آن با runtime اصلی فرض نمی‌شود. |
| آزمایش تشخیصی | آرشیو/خلاصهٔ جدا با ۱٬۰۹۲ ردیف | جانشین ۲۱٬۸۴۰ ردیف اصلی یا ۳٬۰۱٦ ردیف تکرار نیست. |
| B مولد | ٦۴ پرسش، ۱۲۸۰ ردیف شرط و ۳۷٦ پاسخ یکتای واقعی | شواهد مولد برای همان مدل، داده و قاعدهٔ ارزیابی؛ اکنون مادهٔ توسعه و بازتحلیل است. |
| C پیگیری | طرح ٦۲جفتی با کنترل‌های از پیش تعیین‌شده | نتیجه فقط از آرشیو واقعی خودش و با حدود شاخص‌های خودکار گزارش می‌شود. |

شرح مقاله اکنون میان معماری پیشنهادی و اجزای فعال تفاوت می‌گذارد. دلیل تاریخی غیرفعال‌بودن هر جزء، در جایی که سند تصمیم وجود ندارد، نامعلوم باقی گذاشته شده است. توجیه امروز به‌عنوان تصمیم گذشته نوشته نشده است.

## ۴. دادهٔ تاریخی و مسئلهٔ بازتولید

وجود ریپوی RAG-Security-Lab و داده‌های آن تأیید شد. در commit مبنای بررسی، `6f76858df91277e4b962ee94b4286a25cfe08d4d`، ورودی‌های اصلی شامل ۲۲۴ سند، ۲۲۵ قطعه، ۳۶۴ پرسش و ۱۰۴ حمله قابل ردیابی است. بازسازی ورودی‌ها با اسکریپت جداگانه در مرحلهٔ ریسرچ، ۵۶ سند قبلی و ۱۶۸ مشاهدهٔ WDI و ساخت ۳۳۶ پرسش از دو قالب برای هر مشاهده را بررسی کرده است. بنابراین، عبارت مطلق «کد و دادهٔ اصلی موجود نیست» دقیق نبود و در بازنویسی اصلاح شد.

با این حال، دسترسی به ورودی با دسترسی به نتیجهٔ همان اجرا فرق دارد. جست‌وجوی ثبت‌شده شاخه، commit، درخت فایل، release و مواد قابل دسترس مرتبط را بررسی کرد. آرشیو ۲۱٬۸۴۰ردیفی اجرای اصلی، آرشیو ۳٬۰۱۶ردیفی تکرار و نسخهٔ منطبق کد و تنظیمات مؤثر بازیابی نشد. این نتیجه تنها دربارهٔ حدود همان جست‌وجو است؛ به معنی نبود فایل در هر محل یا ازبین‌رفتن آن نیست.

تصمیم عملی، حفظ نتیجهٔ تاریخی با شرح وضعیت و پرهیز از ادعای بازتولید تازه است. اگر آرشیو اصلی بعداً به دست آید، نخست باید شناسهٔ اجرا و هش‌ها تطبیق داده شود؛ سپس بازنمره‌دهی و در صورت امکان بازاجرای همان نسخه انجام شود. اجرای نسخهٔ تازه با شمار ردیف یکسان، در صورت نیاز A′ نام خواهد گرفت و تاریخچه را به‌طور خودکار بازتولید نمی‌کند. ماژول تکرار C نیز یک آزمایش تازه است و جای آرشیو تاریخی معرفی نمی‌شود.

## ۵. ممیزی مرجع و اعتبار مقدار حمله در B

برای تمام ۶۴ پرسش B پروندهٔ پرسش، رابطه، شاهد، قید و مقدار هدف ساخته شد. حاصل ممیزی دستیار نسبت به منبع بایگانی‌شده چنین است:

| محور بررسی | تعداد | معنا |
|---|---|---|
| مرجع پذیرفته نسبت به رابطهٔ منبع | 53 | سازگاری با منبع معین؛ تصدیق مستقل همهٔ واقعیت‌های بیرونی نیست. |
| مرجع مبهم | 5 | دامنه، تاریخ، گردکردن یا رابطه جواب یکتا نمی‌دهد. |
| مرجع نیازمند اصلاح | 6 | رابطه یا انتساب مرجع با پرسش دقیق سازگار نیست. |

| محور بررسی | تعداد | معنا |
|---|---|---|
| مقدار هدف مخالف رابطهٔ دقیق منبع | 54 | شاهد برای غلط‌بودن در همان رابطه موجود است. |
| غلط‌بودن مقدار هدف ثابت نشده | 10 | وجود قید یا ابهام اجازهٔ طبقه‌بندی قطعی موفقیت واقعی حمله را نمی‌دهد. |

سه ردیف نخست، وضعیت مرجعِ همان ۶۴ پرسش را تقسیم می‌کند؛ دو ردیف آخر، محور جداگانهٔ اعتبار مقدار هدف است. این دو محور روی همان موارد هم‌پوشانی دارند و تعدادهای آنان نباید به‌عنوان پرسش‌های مستقل با هم جمع شود.

این نتیجه بر استنتاج اثر مستقیم دارد. برای نمونه، سال تأسیس و سال تجدید سازمان USAAF یک رابطه نیست. «بیش از ۲۳۰» تمام مقادیر بزرگ‌تر از ۲۳۰ را نفی نمی‌کند. عدد ۳۱۱ در نام یک گروه، یک کمیت قابل جمع یا شمارش نیست. همچنان ممکن است رقم یک منبع دربارهٔ شهر، تور یا شخص دیگری باشد. در چنین حالت‌ها، تطبیق عددی به تنهایی کفایت نمی‌کند و بزرگ‌ترکردن عدد مرجع دلیل اثبات غلط‌بودن مقدار تازه نیست.

هیچ مرجع، پاسخ خام یا نمرهٔ قدیمی به‌صورت خاموش تغییر داده نشد. نتیجهٔ کامل ۶۴موردی حفظ گردید. افزون بر آن، یک تحلیل حساسیت پسینی برای ۵۰ مورد کمّیِ هم‌راستا با رابطهٔ منبع آماده شد. در این زیرمجموعه، تولید عدد هدف در شرط هدفمند بدون دفاع ۲۵ مورد و با رتبه‌بندی مجدد ۱۴ مورد بود؛ این ارقام از ۳۴ و ۱۷ مورد در مجموعهٔ کامل جدا است. این زیرمجموعه بعد از ممیزی دادهٔ دیده‌شده انتخاب شده و آزمون تازهٔ دست‌نخورده یا برآورد تأییدشدهٔ ASR معنایی نامیده نمی‌شود.

بازبینی جامع مستقل ۵۶ سند پیشین و تمام واقعیت‌های تاریخی A هنوز تکمیل نیست. پرونده‌سازی B این کار را به‌طور خودکار انجام نداده است. در بستهٔ پیگیری، این تفاوت با وضعیت باز باقی می‌ماند.

## ۶. بازتحلیل پاسخ‌ها و محدودیت معیار خودکار

قاعدهٔ قدیمی B بر تمام 1280 ردیف دوباره اجرا شد و در معیارهای بررسی‌شده 0 اختلاف با جدول بایگانی‌شده یافت شد. این نتیجه، قابلیت بازحساب همان قاعده را نشان می‌دهد. به دلیل استفادهٔ مجدد از پاسخ‌های یکسان، ۱۲۸۰ ردیف شرط فقط 376 پاسخ یکتای واقعی دارد. تعداد ردیف شرط، تعداد فراخوانی مدل و شمار پرسش مستقل سه مقدار متفاوت است.

نسخهٔ تازه، تولید مختصر و سخت‌گیرانهٔ عدد را از حضور عدد در یک جمله جدا می‌کند. نفی، نقل قول، قید، امتناع جمله‌ای و حضور هم‌زمان عدد و UNKNOWN پرچم بازبینی می‌گیرد. میان ۳۷۶ پاسخ یکتا، قاعدهٔ قدیمی ۵۱ مورد دارای مقدار هدفِ تنها شمرده بود؛ شاخص انتخاب سخت‌گیرانه ۴۷ مورد را مشخص

می‌کند. شمار امتناع لفظی قدیمی ۴۱ بود، در حالی که تشخیص زبان امتناع ۴۶ مورد نشان داد. این تغییرها تعریف شاخص را تغییر می‌دهد؛ عدد تازه نباید «صحت معنایی تصحیح‌شده» نامیده شود.

در شرط حملهٔ هدفمند بدون دفاع، ۳۴ پاسخ دارای مقدار هدف بر اساس قاعدهٔ قدیمی، در شاخص سخت‌گیرانه به ۳۱ مورد می‌رسد. با رتبه‌بندی مجدد، ارقام متناظر ۱۷ و ۱۶ است. نام و مخرج هر شاخص در جدول‌ها جدا درج شده است. نفی‌کردن یک مقدار نادرست یا گفتن «این مقدار در سند آمده، ولی قابل تأیید نیست» با پذیرفتن آن یکسان نیست؛ تشخیص نهایی این تفاوت به بررسی معنایی واقعی نیاز دارد.

همچنان سه محور از هم جدا شده است: بازیابی هر دو شاهد لازم؛ پاسخِ هم‌مقدار با مرجع؛ و پذیرش یک ادعای واقعاً غلط. پشتیبانی از زمینه نیز دو معنا دارد: پاسخ ممکن است از متن مسمومِ ارائه‌شده پشتیبانی شود، اما از شاهد پاک معتبر پشتیبانی نشود. این دو حالت در دستورالعمل داوری ستون مستقل دارد.

## ۷. مطالعهٔ تازهٔ C: طرح و وضعیت مشاهده‌شده

مطالعهٔ C برای پاسخ به مقایسه‌ای تازه طراحی شد. استفادهٔ دوباره از B به‌عنوان آزمون دست‌نخورده، پس از مشاهده و ممیزی پاسخ‌های آن، توجیه نداشت. انتخاب C از snapshot ثابت بخش عمومی validation در HotpotQA انجام می‌شود. شناسه‌ها و عنوان‌های تمام ۱۲۸ مورد قبلی، شامل پرسش‌های آزمون و اهداکنندگان، از قاب تازه کنار گذاشته شدند. این اقدام، استقلال از موارد قبلی پروژه را در حدود کنترل‌های ثبت‌شده تقویت می‌کند؛ استقلال از پیش‌آموزش مدل یا اعتبار آزمون مخفی رسمی را ثابت نمی‌کند.

در پلان اولیه ۶۴ جفت پیشنهاد شده بود. بررسی واحدها پیش از هر خروجی تازه نشان داد که طبقهٔ کلی «شمار» می‌تواند فاصله، رتبه، عدد ترتیبی و تعداد موجودیت‌ها را مخلوط کند. بنابراین، دامنه به ۶۲ جفتِ هم‌واحد محدود شد: ۵۷ جفتِ سال تقویمی و ۵ جفتِ جمعیت با تاریخ معین. این تغییر پیش از مشاهدهٔ پاسخ C ثبت شده است؛ انتخاب نمونه بر اساس بهترشدن نتیجه نبوده است. از ۱۹۲ نامزد بررسی‌شده توسط دستیار، ۱۳۵ مورد نسبت به شاهد منبع پذیرفته، ۳۸ مورد کنار گذاشته و ۱۹ مورد حل‌نشده ثبت شد. این بررسی، داوری انسانی نامیده نمی‌شود.

در طبقه‌های نهایی، ۱۱۴ نامزد سال و ۱۱ نامزد جمعیت واجد شرط بودند. جفت‌سازی مجاور بر اساس ترتیب هش، همهٔ ۱۱۴ مورد سال و ۱۰ مورد جمعیت را به کار برد. آخرین مورد جمعیت در همان ترتیب، بدون همتای مجاور باقی ماند و به‌عنوان ذخیرهٔ استفاده‌نشده ثبت شد؛ این مورد پس از مشاهدهٔ نتیجه کنار گذاشته نشده است. پرسش‌ها و مرجع‌های اصلی بازنویسی نشده‌اند. هر ۱۲۴ مورد منتخب با منبع ثابت تطبیق شد و ۱٬۲۴۰ عنوان زمینه در میان آنان مشترک نیست؛ تفاوت عنوان، استقلال کامل معنایی یا خانوادهٔ منبع را اثبات نمی‌کند.

هستهٔ طرح ۶۲۰ متن پاک، پنج شرط و چهار روش دفاع را دربر می‌گیرد. در هر شرط مثبت ۶۲ متن افزوده می‌شود و نسبت آلودگی ۶۲ از ۶۸۲، یعنی ۹٫۰۹٪ است. این نسبت با پوشش تمام هدف‌ها همراه است و سناریوی فشار آزمایشگاهی محسوب می‌شود. کنترل نامرتبط، همان مقدار تعیین‌شده را برای رابطهٔ اهداکننده به کار می‌برد؛ کنترل بی‌ضرر مقدار مرجع پرسش هدف را دارد. طول متن درج‌شده ۱۲۰ واژه تثبیت شده است. در آزمایش زمینهٔ کنترل‌شده، چهار متن اصلی ثابت می‌ماند و فقط یک جایگاه با متن درج‌شده عوض می‌شود؛ هر دو شاهد لازم نگه داشته می‌شوند. ماژول دوزهای ۱، ۲ و ۵ نیز پوشش همان هدف‌ها را ثابت نگه می‌دارد.

مدل مولد مقرر `gpt-4.1-mini-2025-04-14` و مدل بردارساز `text-embedding-3-small` است. سه نوبت فراخوانی تازه، از استفادهٔ مجدد پاسخ یک payload درون همان نوبت جدا می‌شود. این سه نوبت شمار پرسش‌های مستقل را از ۶۲ بیشتر نمی‌کند. میانگین ابتدا درون هر پرسش و سپس میان پرسش‌ها گرفته می‌شود. دامنهٔ کمینه و بیشینهٔ نوبت‌ها توصیف تغییر مشاهده‌شده است و فاصلهٔ اطمینان جمعیت معرفی نمی‌شود.

**وضعیت خوانده‌شده در ساخت این گزارش:** نتیجه از تحلیل خروجی‌های خام تکمیل‌شده و دارای هش منطبق خوانده شد.

| مشخصهٔ آرشیو واقعی | مقدار |
|---|---|
| پرسش / نوبت | 3 / 62 |
| ردیف شرط برنامه‌ریزی‌شده | 5208 |
| payload یکتا در هر نوبت | 853 |
| پاسخ منطقی محفوظ / فراخوانی منطقی برنامه‌ریزی‌شده | 2559 / 2559 |
| پایان عادی / پاسخ بریده / پایان دیگر در فراخوانی‌های یکتا | 0 / 0 / 2559 |
| توکن ورودی / خروجی مولد، فقط فراخوانی‌های متمایز | 7974 / 1786392 |
| هزینهٔ تعهدشدهٔ محافظه‌کارانه، USD؛ مبلغ صورتحساب نیست | 0.7295299000000001 |
| داوری انسانی ثبت‌شده در تحلیل C | 0 |

**نتیجهٔ خودکار اصلی:** درصد انتخاب عددی سخت‌گیرانهٔ مقدار هدف، با میانگین سه نوبت درون هر پرسش؛ این جدول ASR معنایی تأییدشده نیست.

| شرط | دفاع | انتخاب هدف | انتخاب مرجع | هر دو شاهد | دامنهٔ نوبت‌های هدف |
|---|---|---|---|---|---|
| clean | none | 0.00٪ | 59.14٪ | 62.90٪ | 0.00٪ تا 0.00٪ |

| شرط | دفاع | انتخاب هدف | انتخاب مرجع | هر دو شاهد | دامنهٔ نوبت‌های هدف |
|---|---|---|---|---|---|
| clean | rerank | 0.00٪ | 45.70٪ | 35.48٪ | 0.00٪ تا 0.00٪ |
| clean | filter | 0.00٪ | 59.14٪ | 62.90٪ | 0.00٪ تا 0.00٪ |
| clean | filter_rerank | 0.00٪ | 45.70٪ | 35.48٪ | 0.00٪ تا 0.00٪ |
| targeted | none | 37.63٪ | 48.92٪ | 54.84٪ | 35.48٪ تا 38.71٪ |
| targeted | rerank | 20.97٪ | 39.78٪ | 33.87٪ | 20.97٪ تا 20.97٪ |
| targeted | filter | 0.00٪ | 59.14٪ | 62.90٪ | 0.00٪ تا 0.00٪ |
| targeted | filter_rerank | 0.00٪ | 45.70٪ | 35.48٪ | 0.00٪ تا 0.00٪ |
| unrelated | none | 0.00٪ | 57.53٪ | 58.06٪ | 0.00٪ تا 0.00٪ |
| unrelated | rerank | 0.00٪ | 46.24٪ | 37.10٪ | 0.00٪ تا 0.00٪ |
| unrelated | filter | 0.00٪ | 59.14٪ | 62.90٪ | 0.00٪ تا 0.00٪ |
| unrelated | filter_rerank | 0.00٪ | 45.70٪ | 35.48٪ | 0.00٪ تا 0.00٪ |
| benign | none | 0.00٪ | 98.39٪ | 54.84٪ | 0.00٪ تا 0.00٪ |
| benign | rerank | 0.00٪ | 74.19٪ | 33.87٪ | 0.00٪ تا 0.00٪ |
| benign | filter | 0.00٪ | 59.14٪ | 62.90٪ | 0.00٪ تا 0.00٪ |
| benign | filter_rerank | 0.00٪ | 45.70٪ | 35.48٪ | 0.00٪ تا 0.00٪ |
| accepted_label | none | 37.63٪ | 48.92٪ | 54.84٪ | 35.48٪ تا 38.71٪ |
| accepted_label | rerank | 20.97٪ | 39.78٪ | 33.87٪ | 20.97٪ تا 20.97٪ |
| accepted_label | filter | 37.63٪ | 48.92٪ | 54.84٪ | 35.48٪ تا 38.71٪ |
| accepted_label | filter_rerank | 20.97٪ | 39.78٪ | 33.87٪ | 20.97٪ تا 20.97٪ |

در هستهٔ بدون دفاع، شاخص انتخاب هدف در شرط هدفمند 37.63٪ و در شرط نامرتبط 0.00٪ است. با رتبه‌بندی مجدد، مقدار هدفمند به 20.97٪ می‌رسد. اما مواجههٔ متن درج‌شده برابر نیست: درج متناظرِ هدفمند در 100.00٪ و درج متناظرِ نامرتبط در 0.00٪ زمینه‌ها حضور دارد. پس اختلاف هسته، اثر کل خط لولهٔ بازیابی و پاسخ را نشان می‌دهد؛ به‌تنهایی اثر محتوا را در مواجههٔ برابر جدا نمی‌کند.

کاهش تولید هدف نیز به معنی افزایش هم‌زمان کیفیت همهٔ پاسخ‌ها نیست. در مجموعهٔ پاک، انتخاب سخت‌گیرانهٔ مقدار مرجع از 59.14٪ بدون دفاع به 45.70٪ با رتبه‌بندی مجدد رسیده است. این هزینهٔ قالب پاسخ/تطبیق مرجع باید کنار کاهش مقدار هدف دیده شود؛ هیچ‌یک هنوز صحت معناییِ داوری‌شده توسط انسان نیست. تمام سلول‌های اصلی این اجرای تکمیل‌شده پاسخ عادی دارند و سلول نامعلومِ ناشی از نقص اجرا گزارش نشده است.

**کنترل مواجهه:** دو شاهد کامل و دو متن غیرشاهد ثابت‌اند؛ فقط یک جایگاه متن، درون هر پرسش، تغییر می‌کند.

| جایگاه کنترل‌شده | انتخاب هدف | انتخاب مرجع | هر دو شاهد | مواجهه با درج متناظر |
|---|---|---|---|---|
| clean | 0.00٪ | 79.57٪ | 100.00٪ | 0.00٪ |
| targeted | 16.13٪ | 82.26٪ | 100.00٪ | 100.00٪ |
| unrelated | 0.00٪ | 84.41٪ | 100.00٪ | 100.00٪ |
| benign | 0.00٪ | 100.00٪ | 100.00٪ | 100.00٪ |

در این ماژول، هر دو نوع درج هدفمند و نامرتبط حتماً ارائه می‌شوند و هر دو شاهد لازم نیز در تمام موارد باقی می‌مانند. شاخص هدف در شرط هدفمند 16.13٪ و در نامرتبط 0.00٪ است. این مقایسه، مشکل نابرابری مواجههٔ هسته را برای همین زمینه‌های ساخته‌شده رفع می‌کند. با این حال، تفاوت میان 37.63٪ هسته و 16.13٪ کنترل را نمی‌توان فقط به حفظ شاهد نسبت داد؛ متن‌های غیرشاهد، ترتیب و روش ساخت زمینه نیز میان دو ماژول فرق دارد.

**تکرار با پوشش هدف ثابت:** دوز، شمار نسخه‌های یک متن یکسان برای هر هدف است.

| نسخه برای هر هدف | دفاع | انتخاب هدف | انتخاب مرجع | هر دو شاهد |
|---|---|---|---|---|
| 1 | none | 37.63٪ | 48.92٪ | 54.84٪ |
| 1 | rerank | 20.97٪ | 39.78٪ | 33.87٪ |
| 2 | none | 53.76٪ | 31.18٪ | 45.16٪ |
| 2 | rerank | 33.87٪ | 32.80٪ | 29.03٪ |
| 5 | none | 96.77٪ | 1.61٪ | 0.00٪ |
| 5 | rerank | 56.99٪ | 10.75٪ | 6.45٪ |

با افزایش نسخه‌های یکسان، هم رقابت بازیابی و هم ترکیب جایگاه‌های زمینه تغییر کرده است. در دوز پنج بدون دفاع، نبود هر دو شاهد در زمینه با افزایش شاخص هدف همراه است؛ این همراهی، آزمایش تنوع حمله یا جداسازی علّیِ «تکرار» از حذف شاهد نیست. متن‌ها عمداً تکراری‌اند و قطعه‌های یکسان

حذف نشده‌اند. نتیجه به این قالب، همین مدل و همین مجموعه محدود می‌ماند.

تحلیل انتقال جفتی نیز افت خالص را توضیح می‌دهد. در مجموعِ سلول‌های سه نوبت، از 70 رویداد اولیهٔ معیارِ «مواجهه به‌اضافهٔ انتخاب هدف»، 48 مورد پس از رتبه‌بندی مجدد دیگر معیار را ندارد؛ تنها 20 مورد به انتخاب مقدار مرجع می‌رسد و 17 رویداد تازه در خارج از مجموعهٔ اولیه ایجاد می‌شود. این شمارها سلول‌های پرسش–نوبت‌اند، نه همان تعداد پرسش مستقل یا خطای معنایی تأییدشده. بنابراین، پیشگیری، بازیابی مقدار مرجع و تولید هدف تازه باید جدا گزارش شوند.

تمام معیارها، مقایسه‌های جفتی و موارد شکست در `analysis/study_c/` محفوظ است. گروه‌های از پیش تعریف‌شده و انتخاب نمونهٔ توضیحی با هش ثابت نگهداری شده‌اند؛ مثالِ مطلوب جای مجموعهٔ کامل خطاها را نگرفته است.

## ۸. برچسب اعتماد و دامنهٔ دفاع

فیلتر آزمایش، اسناد دارای `verified=True` و برچسب high یا medium را می‌پذیرد. در دادهٔ پایه، تمام متن‌های پاک پذیرفته و تمام درج‌های جدید، حتی درج بی‌ضرر، رد می‌شوند. پس کاهش حمله در این شرط به فرض درست‌بودن برچسب‌ها وابسته است. این طراحی، سامانهٔ احراز هویت سند یا روند نهادی تأیید محتوا را پیاده نمی‌کند.

شرط برچسب پذیرفته، متن و شناسهٔ همان درج هدفمند را نگه می‌دارد و فقط صفات اعتماد را عوض می‌کند. این مقایسه می‌تواند وابستگی دفاع به metadata ورودی را نشان دهد. از آن نمی‌توان وقوع نفوذ واقعی، دورزدن کنترل دسترسی یا شکست امضای دیجیتال را نتیجه گرفت. در نبود شاهد مرجع صلاحیت‌دار، برچسب به سازندهٔ دادهٔ آزمایش نسبت داده شده است.

جلوگیری از تولید مقدار هدف نیز با بازگشت پاسخ درست برابر نیست. ممکن است دفاع مقدار مهاجم را حذف کند، اما شاهد لازم را هم از دست بدهد و مدل امتناع یا عدد دیگری تولید کند. به همین دلیل، پیشگیری، بازگشت مقدار مرجع و خطای تازه در مقایسه‌های جفتی جدا تعریف شده‌اند. نتیجهٔ صفر در یک ستون فقط به همان معیار، نمونه، مدل و فرض برچسب مربوط است.

**حساسیت به رد اشتباه شاهد مشروع:**

| برچسب‌گذاری در آزمون جدا | شمار دارای هر دو شاهد | مخرج | درصد |
|---|---|---|---|
| all_accepted | 39 | 62 | 62.90٪ |
| support_rejected | 0 | 62 | 0.00٪ |
| distractor_rejected | 39 | 62 | 62.90٪ |

این آزمون فقط بازیابی را اندازه می‌گیرد. در هر پرسش، یک شاهد لازم با قاعدهٔ شناسهٔ ثابت رد شده و با رد یک متن غیرشاهد مقایسه شده است. از دست‌رفتن شرط «هر دو شاهد» پس از حذف یک شاهد لازم، پیامد ساختاری همین سنجه است؛ صحت پاسخ مدل یا دسترسی به شاهد معادل را اندازه نمی‌گیرد. برای این ماژول هیچ فراخوانی تازهٔ بردارسازی یا تولید پاسخ انجام نشده و هزینهٔ پاسخ نهایی از آن استنتاج نشده است.

## ۹. کنترول تمامیت اجرا و نگهداری مواد قبلی

در runner تازه، طراحی پیش از بردارسازی و زمینه‌ها و درخواست‌ها پیش از تولید پاسخ منجمد می‌شود. کد و دادهٔ مؤثر، تنظیمات، payload و فایل‌های مرتبط با هش تطبیق می‌گردد. کنترل پیش از هر ارسال و ادامهٔ اجرا، شامل مسیر کش خالی، اعمال می‌شود. تغییر ورودی یا درخواست باید پیش از تماس با سرویس اجرای مرحله را متوقف کند. کنترل مدل برگشتی، ذخیرهٔ پاسخ خام، تعداد تلاش محدود، سقف هزینه و توقف خطای دائمی نیز جدا تعریف شده است.

آزمون‌های آفلاین این مسیر از دادهٔ ساختگی و ارسال‌کنندهٔ ساختگی استفاده می‌کنند. گذشتن آن‌ها شاهد رفتار کد است و آزمایش واقعی C محسوب نمی‌شود. همان‌گونه، دادهٔ ساختگی آزمون در جدول نتیجه یا داوری انسانی وارد نمی‌شود. محیط مشتری و نسخهٔ کتابخانه‌ها ثبت شده، اما سخت‌افزار سرویس مدل و محیط مجهول تاریخی با مشخصات میزبان فعلی پر نشده است.

ثبت تکمیلی محیط محلی در زمان اجرا، پردازندهٔ `INTEL(R) XEON(R) PLATINUM 8573C`، سه پردازندهٔ منطقی قابل مشاهده، سهمیهٔ دو هسته و سقف حافظهٔ ۸ GiB را نشان می‌دهد. این مشاهده با تاریخ خود در `protocol/client_hardware_observation.json` نگهداری می‌شود و اعلامِ پیش از انجماد معرفی نشده است. بردارسازی و تولید متن در سرویس دوردست انجام شده؛ مشخصات این میزبان جای سخت‌افزار نامعلوم سرویس API یا محیط تاریخی را نمی‌گیرد.

یک بررسی محاسباتی جداگانه نیز زنجیرهٔ هش، شناسه‌های پاسخ سرویس، ترتیب دو انجماد و سه نوبت، مصرف توکن و دفتر هزینه را با فایل‌های خام تطبیق داد. این بررسی بدون واردکردن ارزیاب و تحلیل‌گر اصلی، 196 سلول خلاصه و 48 شمار انتقال جفتی را دوباره محاسبه کرد و اختلاف ثبت نشد. تمام 244 فایل مبنای قبلی نیز بدون تغییر باقی است. این شاهدِ تمامیت و بازحساب محاسبه است؛ بازتولید بیرونی یا داوری معنایی انسان محسوب نمی‌شود. رسید آن در `protocol/POSTRUN_QA.json` موجود است.

چهار شکل قبلی حفظ شده‌اند: فلوچارت خط لوله، شکل صحت مقدار پاسخ تاریخی، شکل موفقیت حملهٔ تاریخی و نمودار نتیجهٔ مولد B. هش بایت‌های اصلی در دفتر حفظ اشکال موجود است. شکل تاریخی با شرح تاریخی و محدودیت خود باقی می‌ماند؛ نتیجهٔ تازه نباید روی آن نوشته شود. ساخت مقالهٔ جدید

باید درج هر چهار شکل را نیز بررسی کند، زیرا حفظ فایل به تنهایی به معنی درج صحیح در Word یا PDF نیست.

## ۱۰. یافته‌های بررسی دستی معنایی نویسنده

نویسنده انجام بررسی دستی معنایی ۷۲ مورد پرسش–زمینه–پاسخ را اعلام و یافته‌های آن را ارائه کرده است. نمونهٔ اصلی شامل ۳۲ مورد از B و ۳۲ مورد از C است؛ هشت مورد تشخیصی B جدا بررسی شده‌اند. این بررسی پسینی و توسط نویسندهٔ آگاه از مطالعه انجام شده است. روش جاری، مطالعهٔ توافق بین ارزیابان یا برآورد دقت کل سیستم نیست؛ دامنهٔ ارزیابی جاری همان بررسی موردی نویسنده است.

مبنای قضاوت، معنای ادعا برای موجودیت، رابطه، تاریخ، واحد و قید سؤال بود. شواهد کامل مرجع از زمینهٔ واقعاً ارائه‌شده به مدل جدا دیده شد. اظهار عدد، نقل عدد، نفی آن و امتناع از پاسخ یک نتیجه محسوب نشد. دفتر انتخاب نمونه و یادداشت‌های کمکی دستیار با منشأ خود حفظ شده‌اند؛ جدول زیر خلاصهٔ یافته‌هایی است که نویسنده ارائه کرده و جدول نمره‌های فردی ساختگی برای انسان تولید نشده است.

| نتیجهٔ بررسی نسبت به شواهد منبع | تعداد در نمونهٔ اصلی |
|---|---|
| پاسخ سازگار با منبع | ۴۱ |
| پاسخ مخالف منبع | ۱۶ |
| امتناع کامل، بدون ادعای پاسخ | ۳ |
| نامشخص | ۴ |
| مجموع | ۶۴ |

هشت مورد تشخیصی با نمونهٔ اصلی یکجا به‌عنوان درصد دقت حساب نمی‌شوند؛ این موارد با پرچم‌های خطا انتخاب شده‌اند. در دو مورد، پاسخ هم عدد را اظهار و هم از پاسخ مبتنی بر شواهد امتناع کرده است.

یافتهٔ نخست، پاسخ Koufax است که 1972 را بیان و سپس پاسخ براساس متن‌های داده‌شده را UNKNOWN اعلام می‌کند؛ معیار تطبیق عدد این تعارض را از بین نمی‌برد. یافتهٔ دوم، ابهام شخص در سؤال بازیگر دو سریال است: مرجع 1994 شخص مورد نظر annotation را دنبال می‌کند، در حالی که شواهد موجود تعبیر دیگری با 2013 را پشتیبانی می‌کند. یافتهٔ سوم، حفظ قید «بیش از ۳۰۰۰» است؛ این عبارت، شمار دقیق نیست و به‌تنهایی ۳۰۱۷ را غلط ثابت نمی‌کند. یافتهٔ چهارم، پاسخ‌های سازگار با مرجع است که در زمینهٔ واقعی مدل شاهد کافی ندارند. یافتهٔ پنجم، شاهد پاک جایگزین Operation Ladbroke برای 1943 است، با اینکه یکی از شواهد علامت‌گذاری‌شده حضور ندارد.

این یافته‌ها نشان می‌دهند صحت معنایی، پشتیبانی از زمینه و پوشش شواهد annotation باید جدا گزارش شوند. تمام ۱۸۸ نقل‌قول یادداشت‌های همراه با متن منبع یا پاسخ دقیق تطبیق داده شده‌اند. گزارش نویسنده در manual_review/author_reported_findings.json و شناسه‌ها، پاسخ‌ها، شواهد و منشأ یادداشت‌های کمکی در assistant_review/ قابل بررسی‌اند. یافته‌های نمونه به‌عنوان نرخ پذیرش معنایی ادعای غلط مهاجم در تمام آزمایش تعمیم داده نشده‌اند.

## ۱۱. بازنویسی مقاله و نحوهٔ ارائه به متخصص

نسخهٔ کاری مقاله، شرح معماری واقعی، دسترسی ورودی‌های تاریخی، وضعیت آرشیو، ممیزی مرجع B، تحلیل حساسیت و حدود برچسب اعتماد را بازنویسی می‌کند. رقم قدیمی با رقم بازتحلیل‌شده در یک جدول بدون نام نسخه جایگزین نشده است. چکیده و نتیجه باید روشن سازد که کدام یافته به مطالعهٔ مولد مربوط است و کدام نمودار تنها نتیجهٔ گزارش‌شدهٔ تاریخی را نگه می‌دارد.

ارجاع‌ها و کتابنامه اصلاح شده‌اند. نسخهٔ تحویل شامل مقاله، گزارش، جدول ٦٧ مورد و بستهٔ قابل بازحساب شواهد است. متن نتیجه، تولید عدد هدف را با درصد تأییدشدهٔ پذیرش معنایی ادعای غلط یکسان معرفی نمی‌کند. گزارش بررسی دستی نویسنده و محدودیت نمونه نیز همراه همان نسخه ارائه می‌شود.

## ۱۲. تصمیم عملی دربارهٔ پنج نقد باقی‌مانده

| نقد | اقدام این نسخه | حدی که حفظ شده است |
|---|---|---|
| اعتبار تفسیر معنایی | بررسی دستی معنایی نویسنده بر ۷۲ مورد با یافته‌ها و نمونه‌های مشخص گزارش شد. | درصد موفقیت معنایی برای کل پاسخ‌ها و توافق ارزیابان ادعا نشده است. |
| عیب واقعی بعضی مرجع‌های B | B به شاهد تشخیصی پسینی محدود شد؛ نتیجهٔ اصلی بر C و کنترل‌های آن استوار است. ۵ ابهام، ٦ اصلاح و ۱۰ مقدار با نادرستی ثابت‌نشده با هم‌پوشانی خود حفظ شدند. | خطای مرجع با حذف خاموش یا تغییر معنای سؤال اصلاح‌شده معرفی نمی‌شود؛ حساسیت ۵۰موردی جای مخرج اصلی را نمی‌گیرد. |
| آرشیو تاریخی A | A فقط به‌عنوان زمینهٔ تاریخی نگه داشته شد؛ ورودی‌های موجود و حدود جست‌وجو منتشر می‌شوند. | بازتولید خروجی تاریخی ادعا نمی‌شود و C جانشین اجرای A نامیده نشده است. |
| دسترسی مستقل به شواهد | کد، داده، پاسخ‌های خام، زمینه‌ها، بردارها، هش‌ها و دستور بررسی بدون API در ریپو قرار می‌گیرند. | راستی‌آزمایی محاسبات و تمامیت فایل با تأیید مستقل همهٔ حقایق منبع یکسان نیست. |

| نقد | اقدام این نسخه | حدی که حفظ شده است |
|---|---|---|
| دامنهٔ تعمیم | نتیجه به ۶۲ پرسش، یک snapshot مدل، حملهٔ قالبی و ماژول‌های ثبت‌شده محدود شد. | ادعای تعمیم به مدل‌های دیگر، همهٔ موضوع‌ها یا استقرار نهادی حذف شده است. |

برای متخصص، یک لینک GitHub به نسخهٔ مقاله، گزارش، یافته‌های معنایی و مسیر اجرای بررسی شواهد داده می‌شود. پیشرفت این نسخه، ارائهٔ یافته‌های موردی و امکان بررسی مستقل محاسبات است؛ ارقام آزمایش منجمد برای متفاوت‌نشان‌دادن نتیجه تغییر نکرده‌اند. توسعهٔ بعدی می‌تواند منبع، نوع سؤال و مدل بیشتری را بیازماید، اما چنین آزمایشی در این نسخه انجام‌شده معرفی نمی‌شود.

## ضمیمهٔ الف. نمای پیگیری درخواست‌های متخصص

جدول کامل با اقدام، شاهد، معیار تکمیل و کار باقیمانده در `Implementation_Progress_67_FA.csv` و نسخهٔ JSON همراه موجود است. نمای زیر برای مرور سریع است. واژهٔ «اجراشده» در یک ردیف تنها به همان اقدام محدود است و وضعیت سایر ردیف‌ها را نمی‌بندد.

| شناسه | موضوع درخواست | وضعیت تطبیق |
|---|---|---|
| 3.1.1 | معماری واقعاً اجراشده | اجراشده در مستندسازی |
| 3.1.2 | دلیل انتخاب Hashing و TF-IDF | تاحدی؛ دلیل تاریخی نامعلوم |
| 3.1.3 | علت غیرفعال‌بودن اجزای پیشنهادی | تاحدی؛ دلیل تاریخی نامعلوم |
| 3.1.4 | حداقل یک آزمایش با LLM واقعی، مشروط به ادعای مولد | آزمایش‌های واقعی B و C مستند |
| 3.1.5 | بدیل محدودسازی عنوان و ادعاها | اصلاح ادعا در نسخهٔ کاری |
| 3.2.1 | فهرست منابع اصلی | ورودی‌های موجود ردیابی شده |
| 3.2.2 | انتخاب ۱۶۸ مشاهده و خانواده‌های WDI | بازسازی ورودی انجام‌شده |
| 3.2.3 | شِمای اسناد، قطعه‌ها، پرسش‌ها و پاسخ‌ها | ورودی‌های موجود ردیابی شده |
| 3.2.4 | چگونگی ساخت ۳۶۴ پرسش | تاحدی؛ منشأ دستی محدود |
| 3.2.5 | اعتبار پرسش و پاسخ مرجع | A ردیابی شد؛ صحت مستقل مرجع‌های آن باز است |
| 3.2.6 | وضعیت بازبینی اسناد و برچسب‌های قبلی | تاحدی؛ بازبینی پیشین ثابت نیست |
| 3.2.7 | پیوند ردیابی‌پذیر سند، قطعه و پرسش | ورودی‌های موجود ردیابی شده |

| شناسه | موضوع درخواست | وضعیت تطبیق |
|---|---|---|
| 3.2.8 | وابستگی صورت‌های پرسش در عدم‌قطعیت | قاعدهٔ تحلیل پیاده‌شده |
| 3.3.1 | تمام ۱۰۴ پرسش هدف تاریخی | ورودی‌های موجود ردیابی شده |
| 3.3.2 | پاسخ درست هر هدف تاریخی | هدف‌های A ردیابی شد؛ اعتبار معنایی مستقل باز است |
| 3.3.3 | مقدار نادرست مورد نظر مهاجم | هدف‌های A ردیابی شد؛ اعتبار معنایی مستقل باز است |
| 3.3.4 | متن کامل همهٔ حملات تاریخی | ورودی‌های موجود ردیابی شده |
| 3.3.5 | شناسهٔ منبع متصل به هر حمله | ورودی‌های موجود ردیابی شده |
| 3.3.6 | برچسب‌های اعتماد هر شرط حمله | فرض اعتماد روشن؛ سامانهٔ عملیاتی اجرا نشده |
| 3.3.7 | روند تولید حمله | تاحدی؛ منشأ دستی محدود |
| 3.3.8 | طول، ساختار و شباهت متن حمله | کنترل‌های C ساخته و اجرا شده |
| 3.4.1 | تعریف اجرایی ارزیابی و مثال | کد و مثال اجرایی آماده |
| 3.4.2 | نارمل‌سازی عدد، سال، واحد و اعشار | کد و مثال اجرایی آماده |
| 3.4.3 | بازنمره‌دهی اجرایی در برابر مرجع | B بازتحلیل شد؛ خروجی تاریخی A باز است |
| 3.4.4 | نمونه‌های صحیح، غلط و مبهم ارزیابی | بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده |
| 3.4.5 | مقایسه با نمونهٔ داوری انسانی در صورت امکان | بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده |
| 3.4.6 | تفکیک بازیابی، انتخاب پاسخ و صحت مولد | محورهای ارزیابی جدا شده |
| 3.5.1 | تحلیل جداگانهٔ بازیابی، پاسخ و موفقیت حمله | محورهای ارزیابی جدا شده |
| 3.5.2 | تحلیل افزایش بازیابی و کاهش صحت | تحلیل خودکار B و C انجام‌شده |
| 3.5.3 | تحلیل خطا فراتر از ارقام نهایی | تحلیل خودکار B و C انجام‌شده |
| 3.5.4 | تفسیر محدود صفر ASR | اصلاح ادعا در نسخهٔ کاری |
| 3.6.1 | شیوهٔ تخصیص برچسب اعتماد | فرض اعتماد روشن؛ سامانهٔ عملیاتی اجرا نشده |

| شناسه | موضوع درخواست | وضعیت تطبیق |
|---|---|---|
| 3.6.2 | مرجع صلاحیت تأیید سند | فرض اعتماد روشن؛ سامانهٔ عملیاتی اجرا نشده |
| 3.6.3 | احراز اصالت، صلاحیت و ثبت رویداد metadata | فرض اعتماد روشن؛ سامانهٔ عملیاتی اجرا نشده |
| 3.6.4 | محدودیت فیلتر در بحث و نتیجه | اصلاح ادعا در نسخهٔ کاری |
| 3.6.5 | آزمون تغییر غیرمجاز metadata در صورت امکان | فرض اعتماد روشن؛ سامانهٔ عملیاتی اجرا نشده |
| 3.7.1 | انتخاب اهداف در هر بودجه | نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم |
| 3.7.2 | تفکیک پوشش هدف، شمار موفقیت و نرخ هدف‌های حمله‌شده | قاعدهٔ تحلیل پیاده‌شده |
| 3.7.3 | توصیهٔ دوزهای متعدد با اهداف ثابت | ماژول تازه اجرا و تحلیل شده |
| 3.7.4 | نقش و مقدار seed | نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم |
| 3.8.1 | شاهد درستِ بازیابی‌شده و پاسخ غلط | تحلیل خودکار B و C انجام‌شده |
| 3.8.2 | مواجهه با حمله بدون موفقیت | تحلیل خودکار B و C انجام‌شده |
| 3.8.3 | جلوگیری از حمله بدون بازگشت پاسخ صحیح | تحلیل خودکار B و C انجام‌شده |
| 3.8.4 | اثر تغییر برچسب بر نتیجهٔ حمله | شرط برچسب B و C تحلیل شده |
| 3.8.5 | تحلیل تغییر رفتار بر اثر تکرار | شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا |
| 3.8.6 | پروتکل مستقل و کامل آزمایش تکرار | شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا |
| 4.1 | چکیدهٔ متناسب با روش و محدودیت | بازنویسی در نسخهٔ کاری |
| 4.2 | روش قابل بازسازی | بازنویسی در نسخهٔ کاری |
| 4.3 | تفکیک نتایج اصلی و تکمیلی | بازنویسی در نسخهٔ کاری |
| 4.4 | بحث بر پایهٔ خطا و محدودیت metadata | بازنویسی در نسخهٔ کاری |
| 4.5 | نتیجه‌گیری محدود به شواهد | اصلاح ادعا در نسخهٔ کاری |
| 5.1 | کد کامل آماده‌سازی تا ارزیابی | کد ادامه و بازتحلیل موجود |
| 5.2 | اسناد، قطعه‌ها، پرسش‌ها و مرجع‌ها | ورودی‌های موجود ردیابی شده |
| 5.3 | متن، شناسه، هدف و مقدار حملات | ورودی‌های موجود ردیابی شده |

| شناسه | موضوع درخواست | وضعیت تطبیق |
|---|---|---|
| 5.4 | تنظیمات و seedهای کامل | نسخهٔ تازه روشن؛ عضویت تاریخی نامعلوم |
| 5.5 | خروجی خام هر پرسش، دفاع و دوز | B/C محفوظ؛ آرشیو تاریخی A بازیابی نشده |
| 5.6 | ارزیاب اجرایی Recall، صحت، ASR و مواجهه | کد ادامه و بازتحلیل موجود |
| 5.7 | محیط نرم‌افزار و سخت‌افزار | کنترل اجرا و محیط C مستند |
| 5.8 | منشأ، استخراج، تاریخ دسترسی و بررسی منبع | منشأ نسخه‌دار ثبت؛ تصدیق جامع بیرونی باز است |
| 5.9 | طرح پیشنهادی در برابر معماری اجراشده | اجراشده در مستندسازی |
| 5.10 | مستند مکمل برچسب و تکرار | شکاف تاریخی ثبت؛ مطالعهٔ تازه جدا |
| 5.11 | محدودیت نشر و حقوق استفاده | تاحدی؛ شرایط استفاده باید حفظ شود |
| 6.1 | آغاز با روش و اجزای واقعی | اجراشده در مستندسازی |
| 6.2 | سپس محاسبه و بازتولید نتایج موجود | B بازتحلیل شد؛ خروجی تاریخی A باز است |
| 6.3 | سپس بهبود ارزیابی و عدم‌قطعیت | بررسی دستی معنایی نویسنده انجام و یافته‌ها ثبت شده |
| 6.4 | سپس آزمایش مولد و مکمل متناسب | مطالعهٔ C اجرا و تحلیل شده |
| 6.5 | در پایان بازنویسی بر اساس نتایج تأییدشده | بازنویسی در نسخهٔ کاری |

## ضمیمهٔ ب. مسیر شواهد برای بررسی

| مسیر نسبت به ریشهٔ اصلاحات | محتوا |
|---|---|
| baseline/claims_registry.json و study_registry.json | هویت مطالعه و مرز هر ادعا |
| history/reproducibility_decision.json و bounded_search_results.json | تصمیم بازتولید و حدود جست‌وجوی آرشیو |
| reference_audit/B_reference_cards_v2.json | پروندهٔ مرجع، رابطه، قید و مقدار هدف هر پرسش B |
| evaluation/B_reanalysis_v2_summary.json | تعداد ردیف و پاسخ یکتا، تطبیق قاعدهٔ قدیمی و تشخیص تازه |
| manual_review/author_reported_findings.json | گزارش تجمیعی نویسنده از۷۲مورد و یافته‌های معنایی |
| manual_review/author_reported_findings.json | گزارش نویسنده از بررسی معنایی ۷۲ مورد و یافته‌های نمونه |

| مسیر نسبت به ریشهٔ اصلاحات | محتوا |
| --- | --- |
| protocol/study_c_protocol.json | انتخاب ۶۲جفتی، سؤال تحقیق، کنترل، تکرار، توقف و تحلیل |
| runner/run_study.py و test_run_study.py | کنترل تمامیت و ارسالِ نسخهٔ تازه و آزمون آفلاین |
| /analysis/study_c | خروجی واقعی تحلیل، مقایسه‌های جفتی و موارد شکست، در صورت وجود رسید تکمیل |
| assistant_review/selection_freeze.json و pass1_input_*.json | شناسهٔ نمونه‌ها و متن کامل پرسش، پاسخ و شواهد بررسی‌شده |
| study_c/retrieval_label_stress_summary.json | آزمون جداگانهٔ بازیابی در برابر خطای فرضی برچسب، بدون تولید پاسخ |
| history/figure_preservation_registry.json | شناسه و هش چهار شکل محفوظ |
| manuscript/Working_Manuscript_v2.md | متن کاریِ قابل بازسازی از شواهد موجود |