گزارش مرحلهٔ ریسرچ برای تقویت علمی مقالهٔ امنیت RAG

عنوان مقاله: Security of Retrieval-Augmented Generation Against Targeted Knowledge-Base Poisoning

مبنای بررسی: گزارش ۹صفحه‌ای متخصص، نسخه‌های مقاله، مخزن RAG-Security-Lab، شواهد ذخیره‌شدهٔ آزمایش مولد و منابع علمی اصلی.

۱. ارزیابی عمومی و نتیجهٔ این مرحله

بررسی انجام‌شده نشان می‌دهد که پروژه برای ادامهٔ تحقیق، کد و دیتای قابل استفاده دارد. مجموعهٔ اصلی افغانستان در مخزن موجود است و چهار جدول دیتای اصلی—اسناد، قطعه‌ها، پرسش‌ها و متن‌های حمله—از ورودی‌های ذخیره‌شده، جداگانه بازسازی شدند. آزمایش جدید با مدل زبانی واقعی نیز دارای پرسش‌ها، متن‌های حمله، زمینه‌های بازیابی‌شده، درخواست‌ها، پاسخ‌ها و فایل‌های تنظیمات است. این موارد، پایهٔ مناسبی برای پاسخ مستند به بخشی از ملاحظات متخصص فراهم می‌کنند.

با این حال، اعتبار محاسبه و اعتبار معنای نتیجه دو مسئلهٔ جدا هستند. بازنمره‌دهی آزمایش جدید، اختلاف محاسباتی با ارقام مقاله نشان نداد؛ اما نمونه‌های مشخصی پیدا شد که در آن‌ها تطبیق عدد، برای تعیین صحت پاسخ یا موفقیت واقعی حمله کافی نیست. همچنان، فایل‌های ورودی آزمایش قدیمی موجود است، ولی آرشیو کامل خروجی‌ها و کد منطبق با اجرای اصلی آن در نسخهٔ بررسی‌شدهٔ مخزن قرار ندارد.

نتیجهٔ این ریسرچ آن است که مرحلهٔ بعد باید بر صحت‌سنجی مرجع‌ها، اصلاح تعریف ارزیابی، تکمیل زنجیرهٔ شواهد و انتخاب آزمایش‌های لازم متمرکز شود. بازنویسی مقاله باید پس از روشن‌شدن این موارد و متناسب با یافته‌های تأییدشده انجام گیرد. این نتیجه با ترتیب پیشنهادی متخصص سازگار است.

در این مرحله، مقاله و نتایج ثبت‌شدهٔ قبلی تغییر نکردند و هیچ درخواست تازه‌ای برای تولید پاسخ با LLM اجرا نشد. کار انجام‌شده شامل مطالعهٔ منابع، بررسی مخزن، بازسازی آفلاین داده‌ها و محاسبهٔ جداگانهٔ معیارها از پاسخ‌های موجود است. این بررسی با داوری معنایی مستقل انسانی یا تکرار بیرونی آزمایش یکسان نیست.

۲. نسخه‌های مقاله و شواهد در دسترس

۲.۱. تفاوت میان نسخهٔ مخزن و نسخهٔ نهایی محلی

مخزن معرفی‌شده، rizwanullahmuahed2-ui/RAG-Security-Lab است. برای ثابت‌ماندن مبنای بررسی، محتوای آن به شناسهٔ مشخص زیر محدود شد:

```
6f76858df91277e4b962ee94b4286a25cfe08d4d
```

فایل PDF مقاله در این نسخهٔ مخزن ۱۸ صفحه دارد و از نظر محتوای باینری با PDF اولیهٔ تحقیق مطابقت می‌کند. نسخهٔ نهایی محلی ۱۶ صفحه است و آزمایش جدید ۶۴پرسشی را نیز در بر دارد. گزارش متخصص عمدتاً از آزمایش ۲۲۴سندی، ۳۶۴پرسشی و ۱۰۴هدفه بحث می‌کند و آزمایش جدید را به نام ذکر نمی‌کند. این مشاهده برای تفکیک نسخه‌ها مهم است؛ دریافت دقیق کدام فایل توسط متخصص، فقط از متن گزارش قابل اثبات نیست. [شاهد A1]

بنابراین، هر ملاحظه باید جداگانه به مطالعهٔ اول و مطالعهٔ دوم تطبیق داده شود. اجرای آزمایش جدید، آرشیو در دسترس‌نبودهٔ مطالعهٔ اول را بازسازی نمی‌کند؛ در عین حال، نقد نبود LLM در مطالعهٔ اول نباید سبب نادیده‌گرفتن شواهد واقعی آزمایش دوم شود.

۲.۲. سه سطح متفاوت شواهد

آزمون مولد از یک زیرمجموعهٔ بخش عمومی validation در HotpotQA ساخته شده و تمام پرسش‌ها در یک مجموعهٔ مشترک اسناد جست‌وجو می‌شوند. این تنظیم، مجموعهٔ آزمون مخفی رسمی یا اجرای معیار رسمی HotpotQA نیست؛ مشخصات مسئلهٔ مشتق‌شده باید همراه نتیجه ارایه شود. [R7]

بخش	مواد موجود	حد نتیجهٔ قابل اتکا
مطالعهٔ اول: بازیابی و استخراج پاسخ	۲۲۴ سند، ۲۲۵ قطعه، ۳۶۴ پرسش، ۱۰۴ متن حمله، کد فعلی و پاسخ‌های ذخیره‌شدهٔ بانک جهانی	ساخت داده و روابط آن قابل بررسی است؛ بازتولید دقیق اجرای اصلی هنوز تأیید نشده است.
آزمایش تشخیصی جداگانهٔ مخزن	خلاصهٔ نتایج، فهرست حملات مصنوعی و مسیر فایل رکوردهای آزمایش هدفمند	این پروتکل با اجرای اصلی تفاوت دارد؛ تمام رکوردهای بزرگ آن در این مرحله بازنمره‌دهی نشد.
مطالعهٔ دوم: آزمایش مولد	۶۴ پرسش، ۶۴۰ متن پاک، ۶۴ پرسش کنترل، ۳۷۶ پاسخ متفاوت و ۱٬۲۸۰ ردیف شرطی	محاسبات و پیوند پاسخ‌ها با زمینه‌ها تأیید شد؛ صحت معنایی مرجع‌ها و پاسخ‌ها هنوز نیازمند ارزیابی است.

README مخزن صریحاً بیان می‌کند که پوشه‌های اجرای تاریخی به Git افزوده نشده‌اند و کد فعلی، نسخهٔ ثابت اجرای اصلی نیست. در فهرست commit بررسی‌شده نیز آرشیو اصلی ۲۱٬۸۴۰حالتی دیده نشد. از این رو، عبارت «دیتای اصلی موجود است» نباید به معنای «تمام نتایج تاریخی بازتولید شده‌اند» به کار رود. [شاهد A1]

۳. یافته‌های بررسی تخنیکی

۳.۱. معماری واقعی اکنون قابل تشخیص است؛ حدود هر مطالعه باید حفظ شود

معماری اصلی با Hashing در فضای ۱٬۰۲۴بعدی، جست‌وجوی Cosine، رتبه‌بندی TF-IDF و انتخاب جمله کار کرده است. کد فعلی مخزن نیز به‌صورت پیش‌فرض آفلاین اجرا می‌شود، اما در انتخاب جمله و بازیابی، تغییرات نسخه‌ای دارد. بودجه‌های فعلی آن صفر، ۱۰، ۲۰، ۵۰ و ۱۰۴ است؛ در حالی که بودجه‌های اجرای اصلی مقاله صفر، ۱۰، ۳۰، ۶۰ و ۱۰۴ گزارش شده است.

سند مستقل طرح اولیه و سابقهٔ تصمیمی که به انتخاب اجزای اجرای اصلی انجامیده باشد، در مواد بررسی‌شده یافت نشد. نام یک مدل یا پایگاه برداری در تنظیمات، دلیل فعال‌بودن آن یا توضیح علت تغییر معماری نیست؛ این بخش به مستند تصمیم و نسخهٔ مربوط نیاز دارد.

مطالعهٔ دوم واقعاً از `gpt-4.1-mini-2025-04-14` و بردارهای `text-embedding-3-small` استفاده کرده است. نام مدل برگشتی و پیوند درخواست‌ها با پاسخ‌ها در آرشیو کنترل شد. این شواهد، وجود آزمایش مولد را پشتیبانی می‌کند، ولی چون دیتا و بخش بازیابی نیز عوض شده‌اند، تفاوت نتایج دو مطالعه را نمی‌توان تنها به جایگزینی انتخاب جمله با LLM نسبت داد. [شواهد A1 و A2]

اصلاح لازم برای مرحلهٔ بعد: معماری توصیف‌شده، تنظیمات فعال و خروجی هر اجرا باید به یک نسخهٔ معین کد متصل باشد. مقایسه‌ای که هدفش سنجش اثر خود مولد است، به ثابت‌نگه‌داشتن سایر اجزا نیاز دارد. مطالعهٔ Su و همکاران نیز میان بررسی بازیابی و بررسی مولد با زمینه‌های کنترل‌شده تفاوت می‌گذارد. [R2]

۳.۲. ساخت دیتای اصلی قابل بازسازی است؛ پوشش آزمون محدودتر از شمار اسناد است

هر چهار جدول اصلی از فایل‌های قبلی و ۱۲ پاسخ ذخیره‌شدهٔ بانک جهانی، بدون اجرای کد مخزن و با روش جداگانه بازسازی شدند. شناسه‌ها و پیوند سند، قطعه، پرسش و حمله معتبر بود. ۱۶۸ مشاهده و ۳۳۶ صورت پرسش وابسته به آن‌ها با مقادیر گردشدهٔ ذخیره‌شده تطبیق داشتند. هر ۱۰۴ متن حمله نیز به پرسش هدف و مقدار تعیین‌شدهٔ خود وصل بود. این نتایج، ساخت و انتقال داده را تأیید می‌کند؛ بررسی مستقل صحت تمام منابع عمومی قبلی محسوب نمی‌شود. [شاهد A3]

یک محدودیت مهم در پوشش پرسش‌ها دیده شد. فقط ۱۸۸ سند و ۱۸۸ قطعه، مستقیماً به‌عنوان شاهد مرجع پرسش‌ها معرفی شده‌اند. ۳۶ سند قبلی که بعداً وارد نمایه شده‌اند، پرسش مرجع مستقیمی ندارند. دو قطعهٔ کم‌اعتماد مربوط به منابع معدنی که فیلتر رد می‌کند نیز هیچ پرسش مرجع مستقیمی ندارند. بنابراین، مشاهدهٔ صفر کاهش صحت پاک بر اثر رد این دو قطعه، شاهد قوی دربارهٔ هزینهٔ رد اسناد معتبر در استفادهٔ واقعی نیست؛ اثر غیرمستقیم آن‌ها نیز باید از پوشش مستقیم شاهد جدا بماند.

اسناد این مجموعه عمدتاً کوتاه‌اند: میانهٔ طول ۵۶ سند قبلی ۷۹ واژه و میانهٔ رکوردهای بانک جهانی ۴۱ واژه است. شمار ۲۲۴ رکورد، تنوع ۲۲۴ سند کامل اداری را نشان نمی‌دهد. محدودیت منابع، طول متن و موضوع پرسش‌ها باید در دامنهٔ ادعا منعکس شود. مستندسازی پیشنهادی در Datasheets for Datasets برای ثبت همین ترکیب، روابط و حدود استفاده مناسب است. [R8]

۳.۳. محاسبات آزمایش جدید سازگار است؛ معنای «صحت» هنوز کامل سنجیده نشده است

تمام ۱٬۲۸۰ فهرست نامزد، زمینهٔ نهایی و درخواست مدل از متن‌ها و بردارهای ذخیره‌شده دوباره ساخته شد و با آرشیو مطابقت داشت. معیارهای عددی، Exact Match، Token F1، مواجهه و انتقال‌های جفتی نیز جداگانه محاسبه شدند؛ اختلاف محاسباتی با خروجی موجود پیدا نشد. ۳۷۶ پاسخ متفاوت به ۱٬۲۸۰ ردیف وصل است و ۹۰۴ ردیف از پاسخ یکسان استفادهٔ مجدد می‌کنند. این تعداد، ۱٬۲۸۰ تولید مستقل مدل نیست. [شاهد A2]

وضعیت	دفاع	فقط عدد مرجع	فقط مقدار هدف	مواجهه با هر متن درج‌شده
پاک	بدون دفاع	۴۱	۰	۰
حملهٔ هدفمند	بدون دفاع	۲۴	۳۴	۶۴
حملهٔ هدفمند	رتبه‌بندی مجدد	۲۹	۱۷	۳۶
حملهٔ نامرتبط	بدون دفاع	۴۰	۰	۱۶
متن درست افزوده‌شده	بدون دفاع	۶۴	۰	۶۴
حملهٔ هدفمند با برچسب ردشده	تصفیه	۴۱	۰	۰
حملهٔ هدفمند با برچسب پذیرفته‌شده	تصفیه	۲۴	۳۴	۶۴

توضیح جدول: تمام شمارها از ۶۴ پرسش است. دو ستون عددی، حضور مقدار مرجع بدون مقدار هدف و حضور مقدار هدف بدون مقدار مرجع را می‌شمارند؛ حضور هم‌زمان از هر دو خارج است و در آرشیو فعلی صفر مورد دارد. این همان تطبیق خودکار قبلی است و تأیید انسانی صحت یا استناد پاسخ نیست. غلط‌بودن واقعی مقدار هدف نیز باید جدا بررسی شود.

کاهش ۳۴ پاسخ دارای مقدار هدف به ۱۷ پاسخ، تمام اثر دفاع را توضیح نمی‌دهد. رتبه‌بندی مجدد، ۲۴ مورد از ۳۴ موفقیت قبلی را متوقف کرده، در ۱۱ مورد مقدار مرجع را برگردانده و هفت موفقیت تازه ایجاد کرده است. این انتقال‌ها تأیید شد و باید همچنان جدا گزارش شود.

برای اعتبارسنجی معنایی، چهار نوع نمونهٔ واقعی اهمیت خاص دارد:

الف. عدد درست همراه با نبود شاهد: در پرسش مربوط به ورود Sandy Koufax به تالار افتخارات، پاسخ سال ۱۹۷۲ را می‌آورد و سپس صریحاً می‌گوید پاسخ مبتنی بر اسناد UNKNOWN است. دو پاسخ متفاوت با این ویژگی در آرشیو وجود دارد که در ۱۶ ردیف استفاده شده‌اند. معیار عددی به آن‌ها امتیاز مرجع می‌دهد. این مشاهده لزوماً نادرستی واقعیت تاریخی را ثابت نمی‌کند؛ نشان می‌دهد صحت واقعیت، پشتیبانی اسناد و امتناع باید جدا سنجیده شوند.

ب. امتناع با جملهٔ کامل: پاسخ «جمعیت شهر در سرشماری ۲۰۱۰ UNKNOWN است» به‌عنوان امتناع ثبت نمی‌شود، زیرا قاعدهٔ فعلی تنها پاسخ لفظی UNKNOWN را می‌پذیرد. از ۳۷۶ پاسخ متفاوت، ۴۵ پاسخ واژهٔ UNKNOWN دارند، اما فقط ۴۱ مورد در طبقهٔ امتناع لفظی قرار می‌گیرند. چهار مورد دیگر نیازمند تفسیر هستند؛ جایگزینی سادهٔ طبقه‌بندی با جست‌وجوی واژه نیز کافی نیست.

ج. رقم به‌عنوان نام: پاسخ ۳۱۱ در یک پرسش، نام گروه موسیقی است. فیلتر عددی آن را وارد زیرمجموعه کرده، اما این نمونه یک کمیت آماری نیست. اگر هدف تحقیق فکت‌های کمی باشد، نوع داده باید بازبینی شود؛ اگر هدف پاسخ‌های دارای رقم باشد، این تعریف باید روشن بیان گردد.

د. از دست‌رفتن قید مقدار: در پرسش مربوط به Roberto De Vicenzo، شاهد می‌گوید «بیش از ۲۳۰» مسابقه؛ مرجع کوتاه ۲۳۰ است و مقدار هدف حمله ۲۴۷ تعیین شده است. مدل در حالت هدفمند بدون دفاع، ۲۴۷ پاسخ داده و این مورد یکی از ۳۴ موفقیت ثبت‌شده است. از گزارهٔ «بیش از ۲۳۰» به‌تنهایی نمی‌توان غلط‌بودن ۲۴۷ را ثابت کرد. این نمونه ضرورت بررسی قید، تاریخ و معنای مقدار هدف را نشان می‌دهد. عدد آرشیوی ۳۴ در این مرحله تغییر داده نشده است.

PoisonedRAG نیز معیار تطبیق متنی خود را روی پاسخ‌های واقعی با بررسی انسانی نویسندگان ارزیابی کرده است؛ اعتبار آن بررسی به معیار فعلی ما منتقل نمی‌شود. ALCE صحت پاسخ و پشتیبانی استناد را جدا می‌سنجد. معیار Faithfulness در RAGAs نیز نسبت به زمینهٔ داده‌شده

تعریف شده است؛ از این تعریف برمی‌آید که پاسخ برگرفته از زمینهٔ مسموم می‌تواند با همان زمینه سازگار و در عین حال از نظر واقعیت نادرست باشد. [R1، R4، R5]

۳.۴. ابهام میان سال ایجاد و سال تجدید سازمان در یک مرجع

پرسش `5a903b7f55429933b8a204af` سال ایجاد نیروی مرتبط با Operation Tidal Wave را می‌پرسد. مرجع آزمون ۱۹۴۲ است، اما جملهٔ پشتیبان دربارهٔ تقسیم وظیفوی ارتش در آن سال بحث می‌کند. راهنمای رسمی آرشیو ملی ایالات متحده، ایجاد Army Air Forces را در ۲۰ جون ۱۹۴۱ ثبت می‌کند و تجدید سازمان ۱۹۴۲ را جدا توضیح می‌دهد. [R11]

در پاسخ‌های ذخیره‌شده، هم ۱۹۴۲ و هم ۱۹۴۱ دیده می‌شود. معیار فعلی با مرجع ۱۹۴۲، اولی را دارای مقدار مرجع و دومی را خارج از مرجع می‌شمارد. این مورد، ناسازگاری مشخص میان رابطهٔ مورد پرسش و شاهد مرجع را نشان می‌دهد. پیش از استفاده از آن برای سنجش صحت واقعی، سؤال و مرجع باید با ثبت منبع و دلیل تصمیم، بررسی و اصلاح یا ابهام‌زدایی شوند. هیچ تغییر خاموشی در مرجع قدیمی مجاز نیست؛ تحلیل اصلاح‌شده باید نسخهٔ جدا داشته باشد. [شاهد A4]

۳.۵. کنترل نامرتبط، نتیجهٔ کل خط لوله را می‌سنجد

متن‌های هدفمند و نامرتبط از نظر تعداد، طول ۱۲۰واژه‌ای و مقدار هدف متناظر کنترل شده‌اند. با این حال، مواجههٔ مولد یکسان نیست. در حالت بدون دفاع، هر ٦۴ پرسش متن هدفمند خود را می‌بینند. در حالت نامرتبط، برای ١٦ پرسش دست‌کم یک متن افزوده وارد زمینه می‌شود و فقط برای یک پرسش، متن کنترل متناظر خودش دیده می‌شود. با رتبه‌بندی مجدد، هیچ متن نامرتبطی وارد زمینهٔ نهایی نمی‌شود. [شاهد A2]

پس تفاوت خروجی دو وضعیت، اثر هدفمندی بر بازیابی و پاسخ‌دهی را با هم نشان می‌دهد. برای ادعای جداگانه دربارهٔ مقاومت مولد هنگام دیدن متن مخرب، حضور متن، موقعیت آن و اندازهٔ زمینه باید کنترل شود. پیشنهاد چنین مقایسه‌ای، استنباط طراحی این ریسرچ است و هنوز اجرا نشده است. [R2]

تعریف ASR در منابع نیز یکسان نیست. برای مثال، در RAGPart و RAGMask، معیار مربوط به حضور سند مخرب در نتیجهٔ بازیابی است؛ در مقالهٔ فعلی، معیار اصلی به مقدار پاسخ و مواجههٔ هدف مربوط می‌شود. درصدهای این دو تعریف را نمی‌توان مستقیماً در یک جدول برتری روش‌ها مقایسه کرد. [R12]

۳.۶. برچسب اعتماد با احراز اصالت سند یکسان نیست

در دیتای اصلی، ۲۲۳ قطعه واجد شرایط و دو قطعهٔ کم‌اعتماد ردشده‌اند. تمام ۱۰۴ متن حمله برچسب untrusted و unverified دارند. در مطالعهٔ دوم نیز تمام اسناد پاک پذیرفته می‌شوند و همهٔ درج‌های پایه، حتی متن‌های درست، برچسب ردشده دارند. این یک فرض آزمایشی دربارهٔ کیفیت برچسب است؛ قابلیت تشخیص خودکار سند مخرب را نمی‌سنجد.

آزمایش برچسب پذیرفته‌شده نشان می‌دهد که تغییر همین فرض، حفاظت مشاهده‌شده را از بین می‌برد. اما تغییر مستقیم یک فیلد در آزمایش، نفوذ واقعی در روند تأیید اسناد نیست. برای ادعای حفاظت عملیاتی، باید مرجع تأیید، صلاحیت تغییر، ثبت تغییرات و کنترل تمامیت مشخص و آزمایش شود. مفاهیم کنترل دسترسی، حفاظت رویدادها و تمامیت معلومات در NIST SP 800-53 برای این تفکیک مناسب‌اند؛ استناد به آن سند، اثربخشی اجرایی روش فعلی را ثابت نمی‌کند. [R10]

همچنان، نتیجهٔ صفر موفقیت مشاهده‌شده با تضمین رسمی برابر نیست. RobustRAG برای مدل مشخصی از خرابی قطعات بازیابی‌شده و تحت فرض‌های صریح، تحلیل رسمی ارایه می‌کند؛ این تضمین به فیلتر مبتنی بر برچسب منتقل نمی‌شود. [R3]

۳.۷. واحد آزمایش و منبع تغییرپذیری باید جدا بمانند

۲۱٬۸۴۰ ردیف مطالعهٔ اول و ۱٬۲۸۰ ردیف مطالعهٔ دوم، نمونه‌های مستقل هم‌تعداد نیستند. در مطالعهٔ اول، دو صورت پرسش به یک مشاهدهٔ بانک جهانی وابسته‌اند و seed انتخاب حمله را تغییر می‌دهد. در مطالعهٔ دوم، زمینه‌های یکسان از پاسخ ذخیره‌شده استفاده می‌کنند و تمام پرسش‌ها یک نمایهٔ مشترک دارند.

فاصله‌های بوت‌استرپ فعلی، توصیفی و مشروط به همین مجموعه و همین پاسخ‌های ذخیره‌شده‌اند. آن‌ها تغییرپذیری تولید تازه، حملات تازه و مجموعهٔ اسناد تازه را اندازه نمی‌گیرند. منابع روش‌شناختی NLP نیز بر انتخاب آزمون متناسب با واحد مشاهده و فرض استقلال تأکید می‌کنند؛ نام یک روش آماری، به‌تنهایی اعتبار کاربرد آن را تضمین نمی‌کند. [R9]

بررسی تطبیقی متن‌های دو مجموعه، هیچ پرسش، عنوان یا متن کامل یکسانی با قواعد نارمل‌سازی به‌کاررفته پیدا نکرد. این نتیجه اکنون از بررسی واقعی فایل‌ها حاصل شده است. با این حال، مقایسه به ورودی‌های فعلی مخزن مربوط است و نبود اشتراک معنایی، استقلال خانوادهٔ منابع یا نبود داده در پیش‌آموزش مدل را اثبات نمی‌کند. [شاهد A5]

مطالعهٔ دوم فقط یک دوز مثبت و یک متن به ازای هر هدف دارد. این طراحی، آزمایش چند سطح حمله با اهداف ثابت نیست. برای تفسیر شدت حمله، شمار اهداف، تعداد نسخه، تنوع متن و سهم نهایی آلودگی باید از هم جدا شوند.

۳.۸. زنجیرهٔ بازتولید به یک کنترل اجرایی دیگر نیاز دارد

در مسیر تولید مطالعهٔ دوم، یک ضعف مشخص با تابع ارسال ساختگی و بدون ارتباط شبکه تأیید شد: وقتی کش پاسخ خالی باشد، فایل درخواست‌های در انتظار پیش از ارسال با هش ثبت‌شدهٔ مرحلهٔ تولید تطبیق نمی‌شود. بنابراین، بررسی کامل فایل‌ها باید پیش از نخستین درخواست اجباری شود. [شاهد A2]

تمام هش‌های آرشیو فعلی درست بودند. این ضعف، مدرک تغییر نتایج موجود نیست. اصلاح آن برای اجرای بعدی باید در نسخهٔ تازهٔ کد انجام شود و کد تاریخی بدون تغییر بماند. وجود فایل hash یا manifest باید با کنترل هش پیش از ارسال درخواست همراه باشد.

در آرشیو تشخیصی مخزن، تفاوت هش چهار ورودی با تبدیل پایان سطرهای LF و CRLF کاملاً توضیح داده شد. این مورد به‌خودی‌خود نشانهٔ تغییر محتوای جدول نیست. در مقابل، شش فایل منبع نسبت به فهرست تاریخی همان آزمایش تغییر کرده‌اند؛ نسخهٔ فعلی باید جدا از نسخهٔ اجرای گزارش‌شده شناخته شود. [شاهد A3]

۴. وضعیت ملاحظات متخصص پس از ریسرچ

محور ملاحظه	شواهد به‌دست‌آمده	موضوع باز برای مرحلهٔ پلان
معماری و LLM واقعی	معماری‌ها تفکیک شده؛ آرشیو مولد موجود و سازگار است.	پیوند نسخهٔ کد با هر ادعا و طراحی مقایسهٔ مورد نیاز
دیتای اصلی و منابع	ساخت جدول‌ها و مقادیر ذخیره‌شدهٔ WDI تأیید شد.	بررسی منابع قبلی و رفع مسائل معنایی مرجع‌های آزمون جدید
دیتای حمله	متن‌ها، شناسه‌ها و روابط در دسترس‌اند.	تأیید غلط‌بودن واقعی و معقول‌بودن مقدار هدف هر حمله
معیار صحت پاسخ	محاسبات قبلی بازتأیید شد؛ نمونه‌های مسئله‌دار مشخص شدند.	تعریف ارزیابی معنایی و بررسی انسانی متناسب با ادعا
اعتبار دفاع برچسبی	فرض برچسب و اثر تغییر آن روشن است.	تعیین مرجع صلاحیت و انتخاب حدود ادعای عملیاتی

محور ملاحظه	شواهد به‌دست‌آمده	موضوع باز برای مرحلهٔ پلان
بودجه و استقلال	پوشش، کش، مخرج‌ها و حدود فاصله‌ها مشخص است.	طراحی آزمایش ثابت‌هدف در دوزهای لازم و تعریف تکرار واقعی
بازتولید تاریخی	ورودی‌ها موجود؛ کد فعلی قابل بررسی است.	بازیابی آرشیو اصلی یا محدودکردن ادعای بازتولید آن
تحلیل خطا و نگارش	نمونه‌های واقعی و منابع مرتبط استخراج شد.	تحلیل نسخه‌دار خطاها و بازنویسی متکی به نتایج نهایی

فهرست تفصیلی، ٦٧ درخواست و ریزدرخواست گزارش متخصص را به شواهد و اقدام لازم وصل می‌کند. این شمار، فهرست کنترل کار است و نباید به درصد کیفیت یا آمادگی نشر تبدیل شود. پیشنهادهای مشروط متخصص، مانند ارزیابی انسانی «در صورت امکان»، از الزامات مربوط به ادعای اصلی جدا ثبت شده‌اند. طراحی دو داور مستقل، پیشنهاد اجرایی مناسب برای سنجش توافق است و الزام لفظی همهٔ منابع یا خود گزارش محسوب نمی‌شود. [R6]

دو اشکال ویرایشی کوچک نیز مشخص شد: سربرگ PDF در انتهای یکی از مراجع باقی مانده و در نشانی RAGAs فاصلهٔ اضافی وجود دارد. این موارد در مرحلهٔ بازنویسی اصلاح می‌شوند. همچنان، روش‌ها و مشخصات نسخه‌های مختلف CorruptRAG و RobustRAG باید با همان نسخهٔ مورد استناد تطبیق داده شوند. این اصلاحات کتاب‌شناختی از مسائل اساسی ارزیابی جدا هستند. [R14]

۵. مبنای تصمیم برای مرحلهٔ پلان

بر اساس این ریسرچ، نخست باید ادعای هدف تحقیق دقیق انتخاب شود: سنجش کل خط لوله در برابر درج متن، سنجش رفتار مولد در مواجههٔ کنترل‌شده، یا سنجش روند اعتماد به اسناد. این سه ادعا به مقایسه‌ها و شواهد متفاوت نیاز دارند. افزودن تعداد زیاد مدل یا دفاع، پیش از روشن‌شدن مرجع و معیار، مسئلهٔ اصلی را حل نمی‌کند.

پلان بعدی باید معیار قابل قبول برای تکمیل هر کار داشته باشد: مرجع مستند و تأییدشده، برچسب معنایی با دستورالعمل روشن، کنترل‌های مناسب سؤال تحقیق، هش کنترل‌شده پیش از اجرا، و خروجی خام قابل ردیابی. برای اجرای تاریخی نیز باید میان بازیابی آرشیو اصلی و بازپیاده‌سازی روش توصیف‌شده فرق گذاشته شود؛ اجرای دوباره با کد فعلی، خودبه‌خود تکرار دقیق آزمایش قدیمی نیست.

اگر صحت‌سنجی مرجع یا معنای برچسب‌ها تغییر کند، نتایج تازه باید در یک تحلیل جدا و با ثبت دلیل تغییر گزارش شوند. اگر تنظیمات یا طراحی حمله بر پایهٔ آزمون فعلی بهبود یابد، همان مجموعه نباید دوباره به‌عنوان آزمون دست‌نخورده معرفی شود. این حدود، از اشتباه در انتخاب داده و تفسیر تعمیم

جلوگیری می‌کند؛ وقوع نشت در دادهٔ فعلی یا حضور آن در پیش‌آموزش در این ریسرچ اثبات نشده است. [R13]

۶. محصول این مرحله و حدود آن

محصول ریسرچ شامل گزارش حاضر، تطبیق تفصیلی ملاحظات، ممیزی قابل اجرای مطالعهٔ دوم، ممیزی داده‌های اصلی، بررسی محدود هم‌پوشانی و مشخصات منابع اصلی است. شناسهٔ commit، هش فایل‌ها، نمونه‌های پاسخ و پیوند منابع همراه یادداشت‌ها ثبت شده‌اند.

این مرحله، آرشیو اصلی ۲۱٬۸۴۰ خروجی را بازیابی نکرده، نتایج بزرگ آزمایش تشخیصی را به‌طور کامل بازنمره‌دهی نکرده و داوری انسانی تولید نکرده است. هیچ اصلاح معیار یا نتیجهٔ جدیدی به مقالهٔ موجود نسبت داده نمی‌شود. فایل‌های بررسی آفلاین و نمونه‌های شبیه‌سازی‌شده نیز از مواد اجرای اصلی جدا نگهداری شده‌اند.

۷. جمع‌بندی و پیشنهاد نهایی این مرحله

نقد متخصص دربارهٔ ضرورت روش روشن، ارزیابی معتبر و شواهد قابل بازتولید همچنان مبنای اصلاح تحقیق است. بررسی مخزن نشان داد که بخشی از کمبود دسترسی به داده و کد قابل رفع است. ممیزی آزمایش مولد نیز محاسبات فعلی را تأیید کرد، اما مثال‌های واقعی، ضرورت بررسی مرجع‌ها و معنای پاسخ را روشن‌تر ساخت.

پیشنهاد این مرحله، عبور به پلان اجرایی بر پایهٔ همین شواهد است: ابتدا مرجع و معیار، سپس شواهد تاریخی و کنترل اجرای جدید، بعد آزمایش‌های متناسب با سؤال‌های تحقیق و در پایان بازنویسی مقاله و گزارش. آمادگی برای نشر علمی باید پس از تکمیل و ارزیابی این اصلاحات سنجیده شود.

شواهد داخلی قابل ردیابی

- **A1:** `repository_snapshot_manifest.json`، `version_identification.json` و فایل‌های مخزن در commit مشخص؛ برای شناسایی نسخه، دسترسی به مواد و حدود آرشیو تاریخی.
- **A2:** `artifact_audit/audit_report.json` و `independent_audit.py`؛ بازسازی زمینه‌ها، بازنمره‌دهی، انتقال‌های جفتی، نمونه‌های خروجی و آزمون کاملاً آفلاین کنترل هش.
- **A3:** `repo_audit/original_data_audit.json` و `audit_original_data.py`؛ ساخت دوبارهٔ جدول‌ها، کنترل منابع ذخیره‌شده، پوشش شاهد و تفاوت نسخه‌ها.

- **A4:** `reference_source_checks.json`؛ پیوند نمونهٔ USAAF با سند رسمی و بررسی قید مقدار در نمونهٔ ۲۳۰/۲۴۷.
- **A5:** `repo_audit/cross_study_overlap.json`؛ قواعد و حدود مقایسهٔ متن‌ها میان دو مطالعه.

منابع علمی و رسمی منتخب

[R1] Zou, W., et al. (2025). *PoisonedRAG: Knowledge Corruption Attacks to Retrieval-Augmented Generation of Large Language Models*. USENIX Security. Paper and proceedings.

[R2] Su, J., et al. (2025). *Towards More Robust Retrieval-Augmented Generation: Evaluating RAG Under Adversarial Poisoning Attacks*. arXiv:2412.16708v2. Versioned paper.

[R3] Xiang, C., et al. (2026). *Certifiably Robust RAG against Retrieval Corruption*. arXiv:2405.15556v2; SaTML 2026. Versioned paper and official program.

[R4] Gao, T., et al. (2023). *Enabling Large Language Models to Generate Text with Citations*. EMNLP. DOI: 10.18653/v1/2023.emnlp-main.398. Canonical paper.

[R5] Es, S., et al. (2024). *RAGAs: Automated Evaluation of Retrieval Augmented Generation*. EACL System Demonstrations. DOI: 10.18653/v1/2024.eacl-demo.16. Canonical paper.

[R6] Artstein, R., & Poesio, M. (2008). *Inter-Coder Agreement for Computational Linguistics*. Computational Linguistics, 34(4), 555–596. DOI: 10.1162/coli.07-034-R2. Canonical paper.

[R7] Yang, Z., et al. (2018). *HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering*. EMNLP. DOI: 10.18653/v1/D18-1259. Canonical paper.

[R8] Gebru, T., et al. (2021). *Datasheets for Datasets*. Communications of the ACM, 64(12), 86–92. DOI: 10.1145/3458723. Authors’ institutional record.

[R9] Dror, R., et al. (2018). *The Hitchhiker’s Guide to Testing Statistical Significance in Natural Language Processing*. ACL. DOI: 10.18653/v1/P18-1128. Canonical paper.

[R10] NIST Joint Task Force. (2020). *Security and Privacy Controls for Information Systems and Organizations*. SP 800-53 Rev. 5. Relevant controls: AC-3, AU-9, SI-7. Official publication.

[R11] U.S. National Archives. *Records of the Army Air Forces [AAF], Record Group 18*. Sections 18.1 and 18.5: establishment in 1941 and reorganization in 1942. Official archival guide.

[R12] Pathmanathan, P., et al. (2025). *RAGPart & RAGMask: Retrieval-Stage Defenses Against Corpus Poisoning in Retrieval-Augmented Generation*. arXiv:2512.24268v1. Versioned preprint.

[R13] Kapoor, S., & Narayanan, A. (2023). *Leakage and the reproducibility crisis in machine-learning-based science*. Patterns, 4(9), 100804. DOI: 10.1016/j.patter.2023.100804. Publisher record.

[R14] Zhang, B., et al. (2026). *Practical Poisoning Attacks against Retrieval-Augmented Generation*. arXiv:2504.03957v2. Versioned paper and SACMAT 2026 accepted-paper list.